Базы данных

А1. Введение в базы данных

Московский государственный технический университет
имени Н.Э. Баумана

Факультет ИБМ

Фев 2025 года

Москва

Артемьев Валерий Иванович © 2025

От моделей к проектированию данных

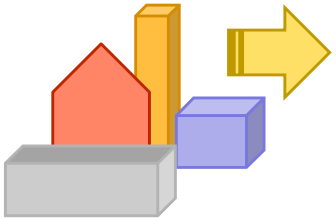

Реальный мир

Описательная деятельность

документирование некоторых аспектов реального мира

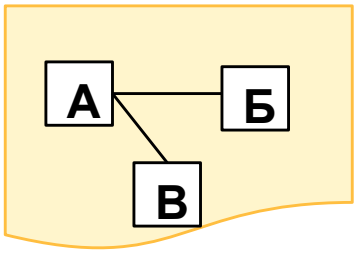

Модель данных

Автоматизация проектирования

Проектная деятельность

создание структур данных, удовлетворяющих набору требований

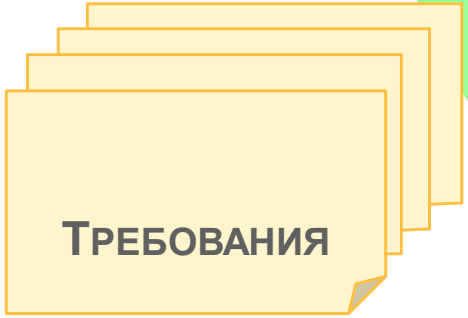

Требования

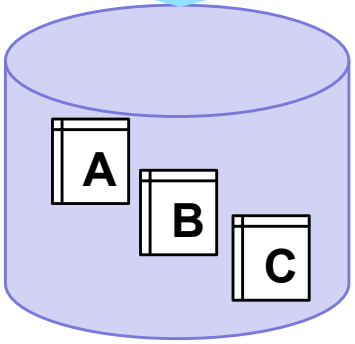

Структуры данных

Виды информационных систем

Информационная система (ИС) – комплекс программно-технических средств *сбора, хранения, актуализации и обработки информации* для поддержки определённого вида деятельности (*предметной области*).

Классы ИС по *типу хранимой и обрабатываемой информации*

Документальные системы
(текст, мультимедиа, дескрипторы и полнотекстовой поиск, гипертекст): ИПС и библиотечные системы, электронный документооборот, сайты и порталы

Геоинформационные системы
(топология, электронная карта) – аналитические системы и ситуационные центры с пространственно-географическим компонентом (транспорт, ЖКХ, месторождения, архитектурное наследие и т.п.)

Фактографические системы
(записи о фактах, БД) – учётно-операционные системы и системы поддержки принятия решений (аналитические системы)

Системы искусственного интеллекта
(временные ряды, языковые модели и т.п.) прогнозные модели, рекомендательные и предписывающие системы, LLM-системы

Всё чаще начинают преобладать **гибридные ИС**

Понятие базы данных

База данных (БД) – *именованная совокупность хранимых данных* о состоянии и отношении объектов предметной области, определённым образом структурированная для обработки, а также *метаданные* – технические описания структуры и содержания данных (схемы данных) в виде словаря-справочника данных.

Контейнеры для хранения БД в виде «сырых данных» и файлов:

- накопители на магнитных дисках,
- твердотельные диски (SSD),
- системы хранения данных (СХД),
- флэшки и карты памяти,
- оперативная память,
- CD/DVD (резервные копии),
- магнитные ленты (резервные копии)

Наличие метаданных позволяет говорить о «самодокументированности» БД

Входные, выходные и хранимые данные

Входные данные –принимаются приложением (ввод с клавиатуры, файлы), может стать причиной изменения хранимых данных.

Выходные данные – сообщения, результаты на дисплей / печать, выходные файлы, выдаваемые приложением, могут получаться из входных и хранимых данных после их обработки.

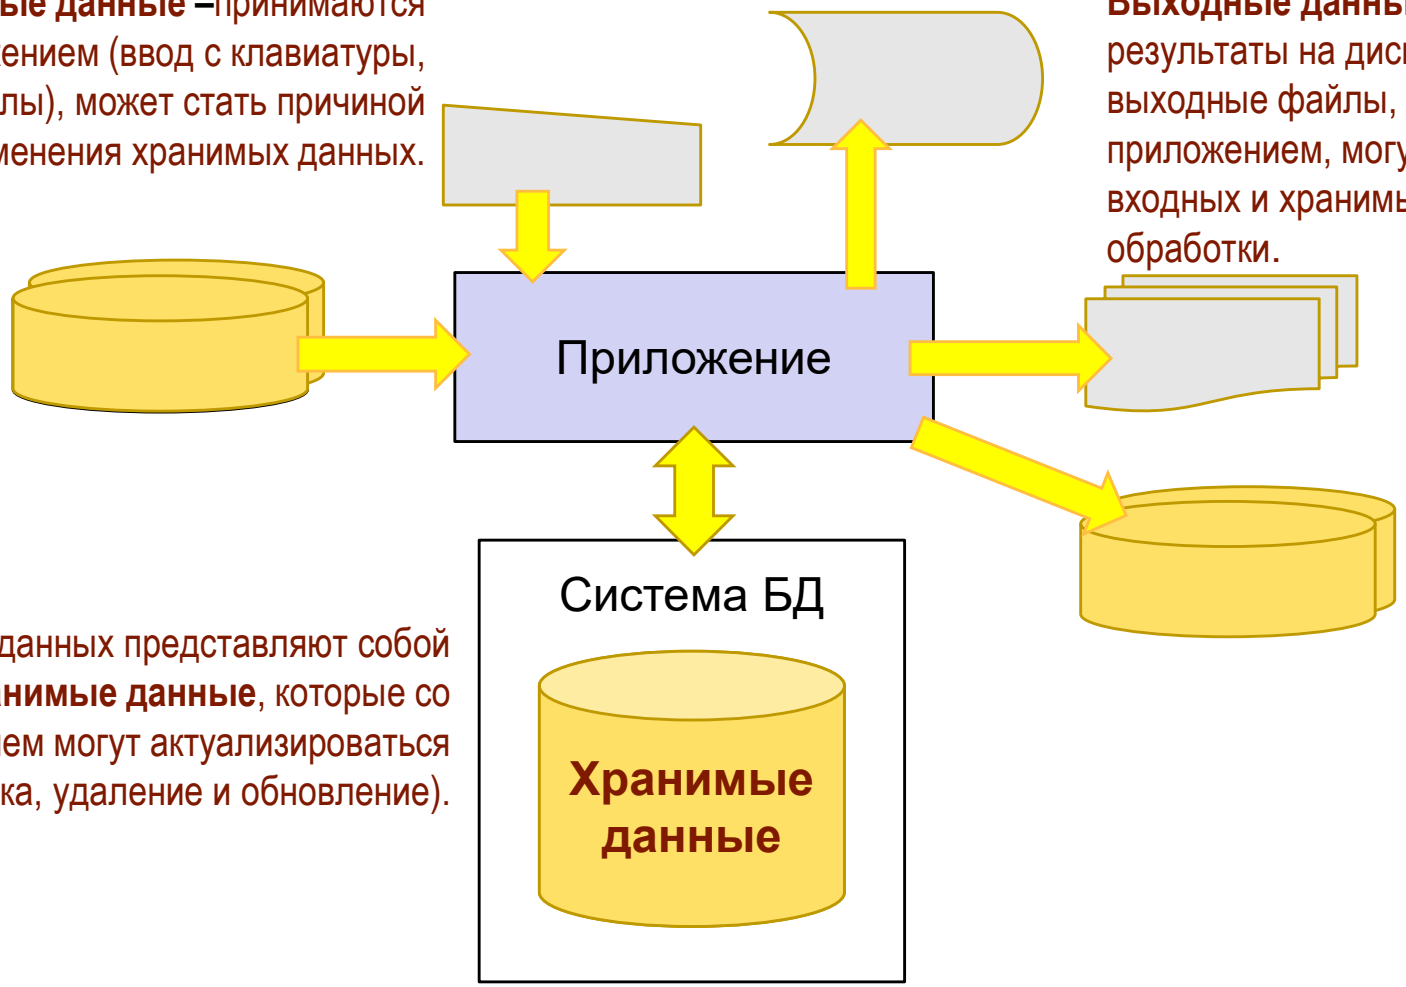

Базы данных представляют собой **хранимые данные**, которые со временем могут актуализироваться (вставка, удаление и обновление).

В общем случае транзитные (входные и выходные) данные не являются частью БД.

Пример различия входных, выходных и хранимых данных

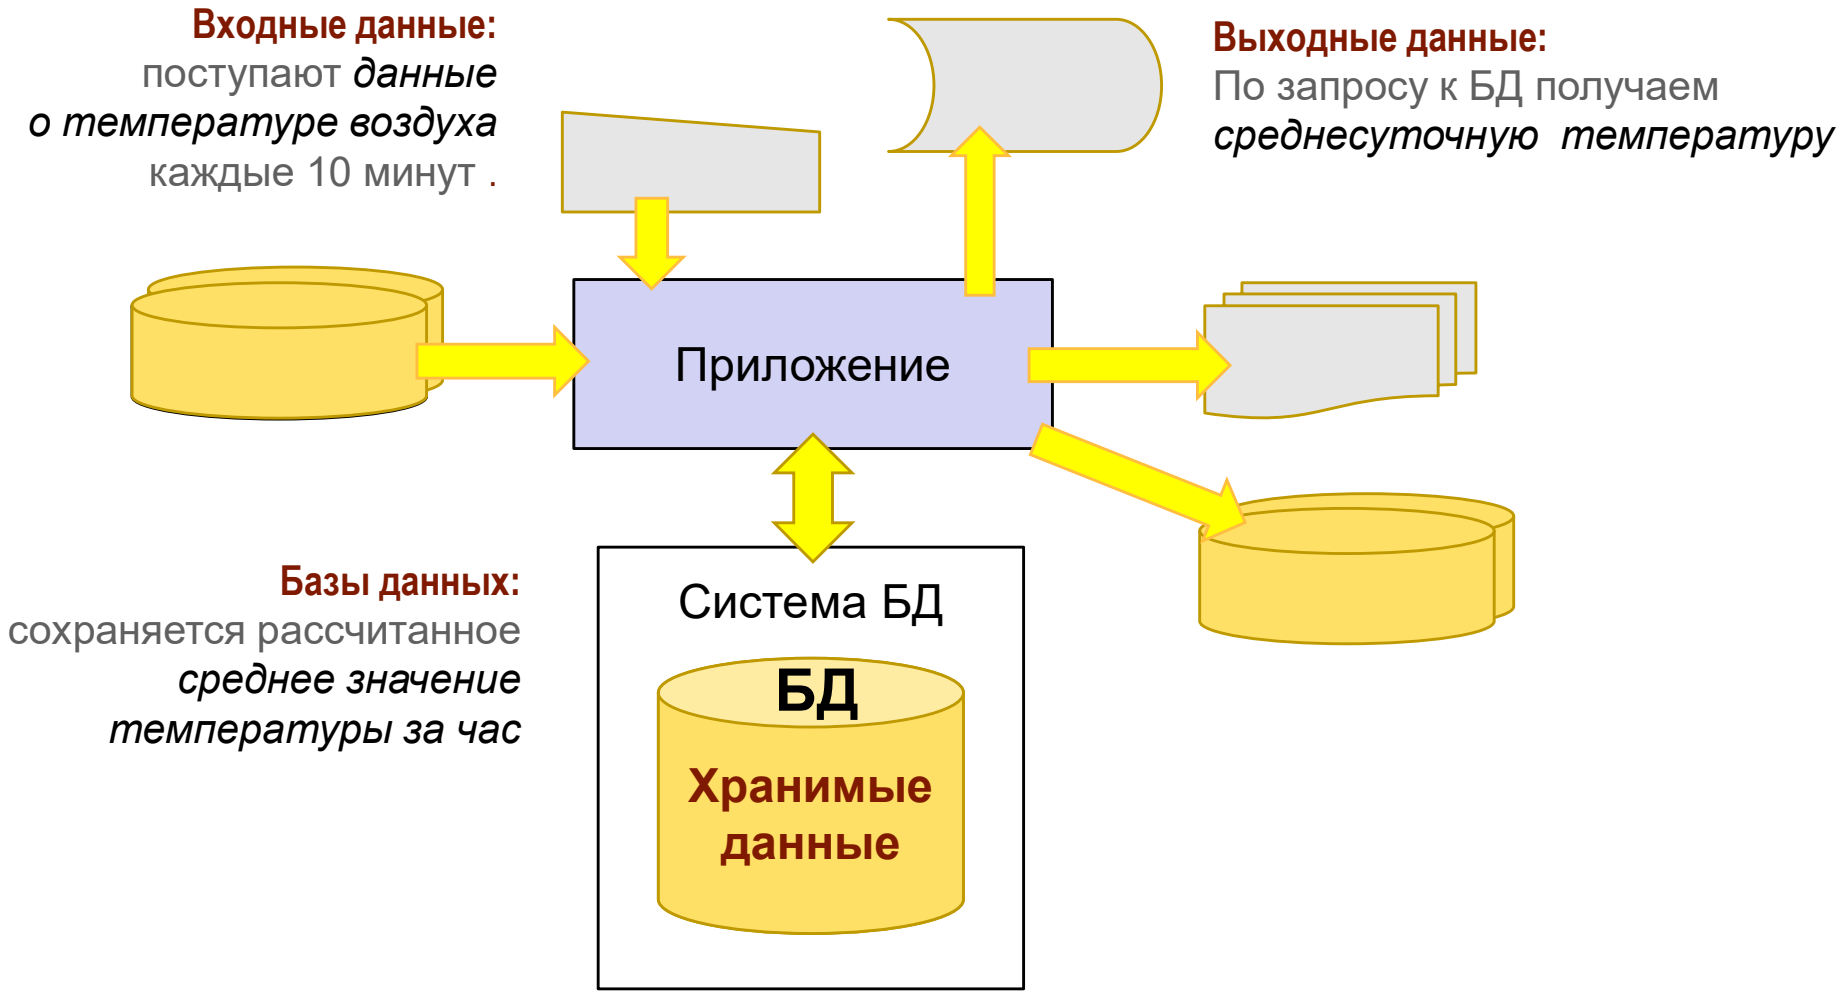

В этом случае хранимые значения будут отличаться
и от входных и от выходных данных.

Понятие СУБД и системы баз данных

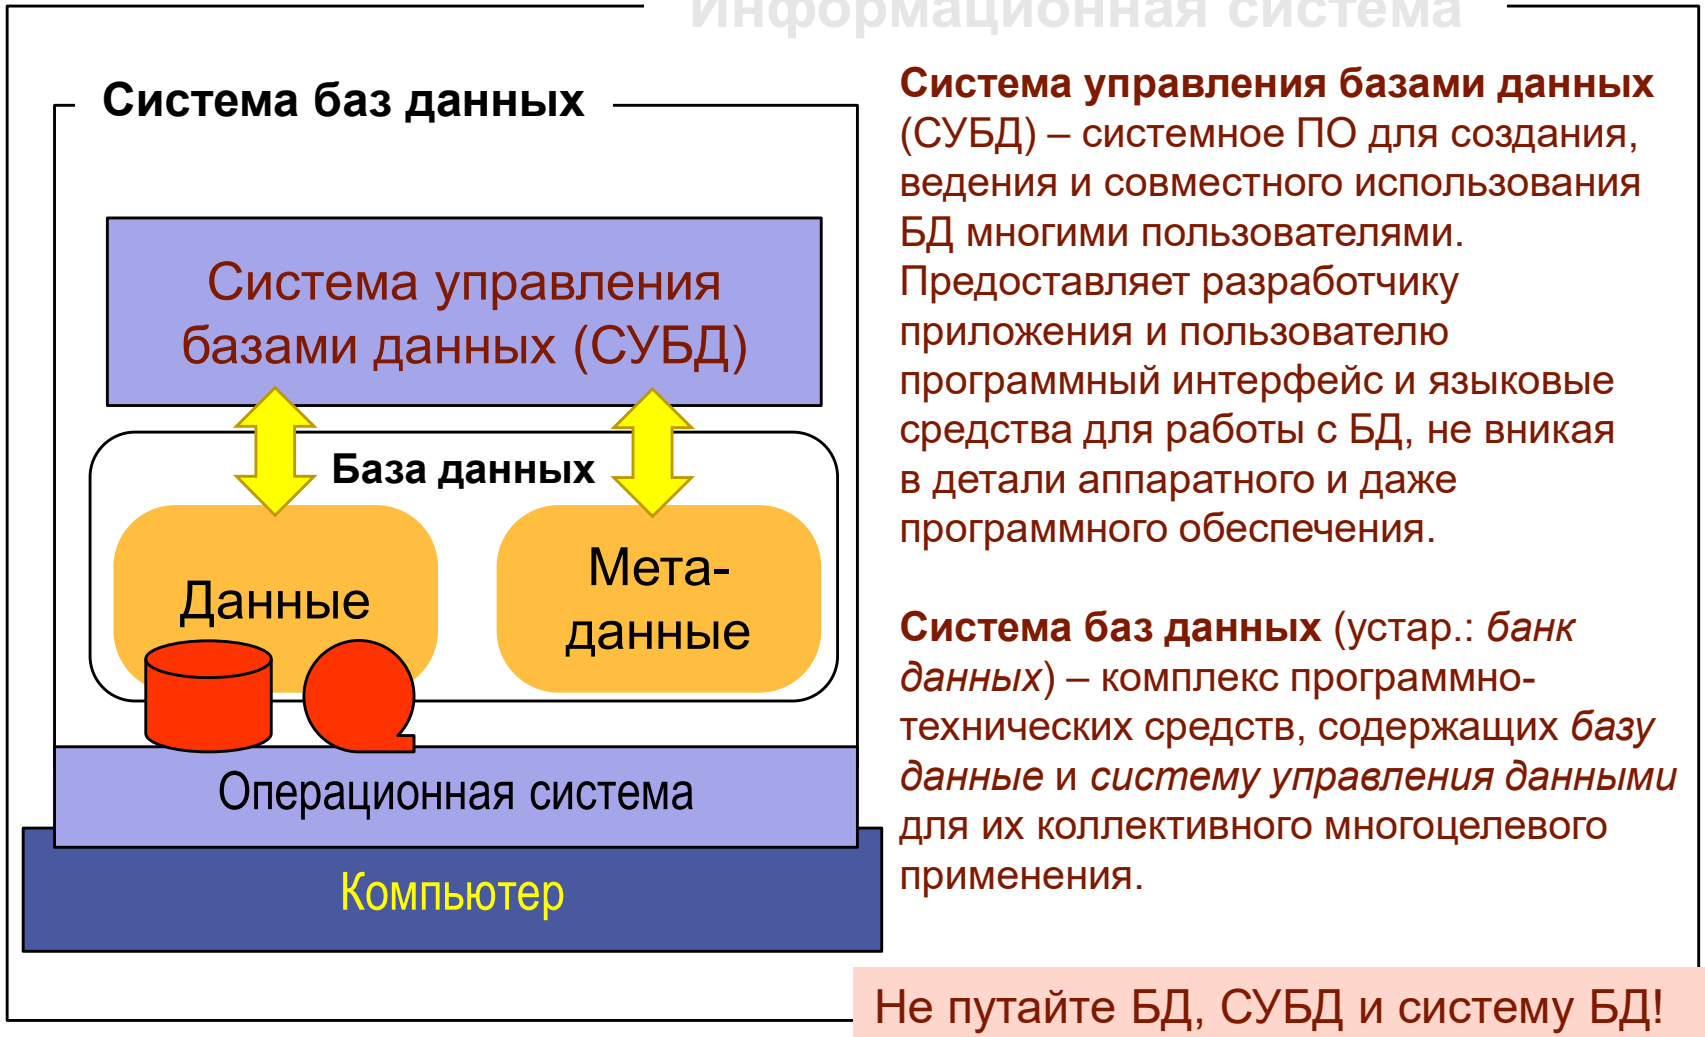

Система управления базами данных (СУБД) – системное ПО для создания, ведения и совместного использования БД многими пользователями. Предоставляет разработчику приложения и пользователю программный интерфейс и языковые средства для работы с БД, не вникая в детали аппаратного и даже программного обеспечения.

Система баз данных (устар.: *банк данных*) – комплекс программно-технических средств, содержащих *базу данные* и *систему управления данными* для их коллективного многоцелевого применения.

Не путайте БД, СУБД и систему БД!

БД без СУБД и прикладного программного обеспечения «не живут»!

Место системы баз данных в ИС

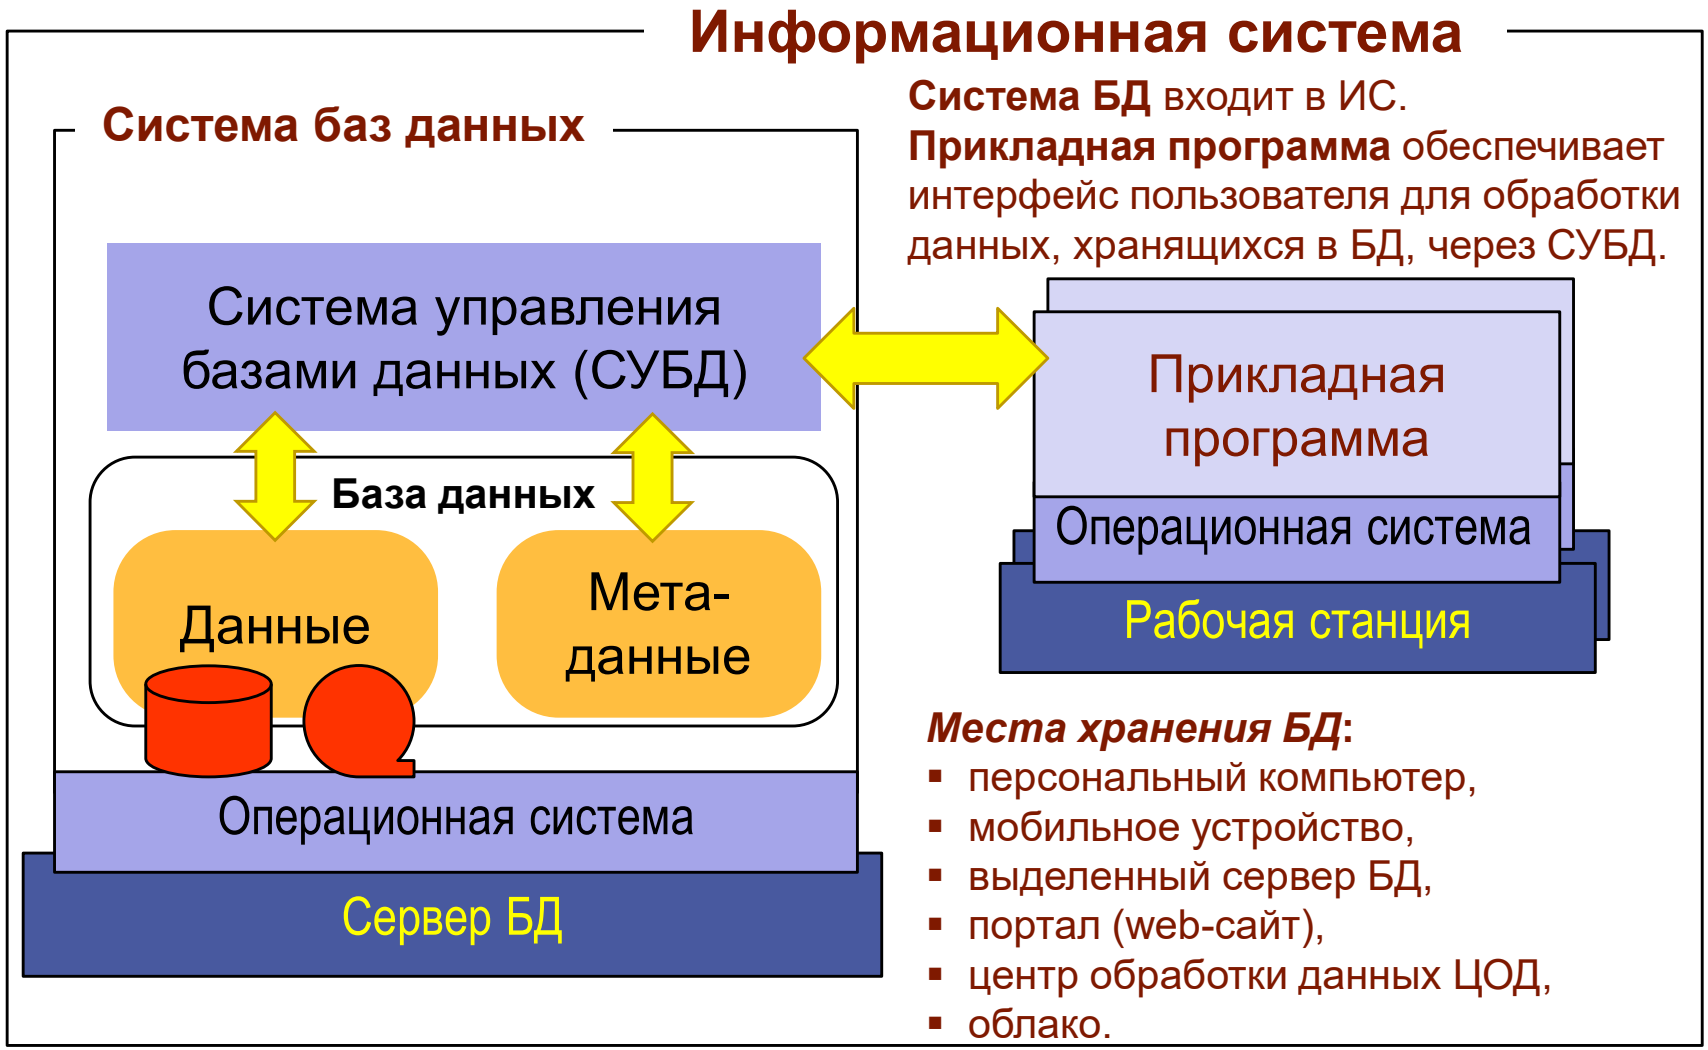

Система БД входит в ИС.
Прикладная программа обеспечивает интерфейс пользователя для обработки данных, хранящихся в БД, через СУБД.

***Места хранения БД*:**

- персональный компьютер,
- мобильное устройство,
- выделенный сервер БД,
- портал (web-сайт),
- центр обработки данных ЦОД,
- облако.

Ориентация на приложение: раньше система БД являлась частью ИС

Современный взгляд на отношение приложений и системы БД

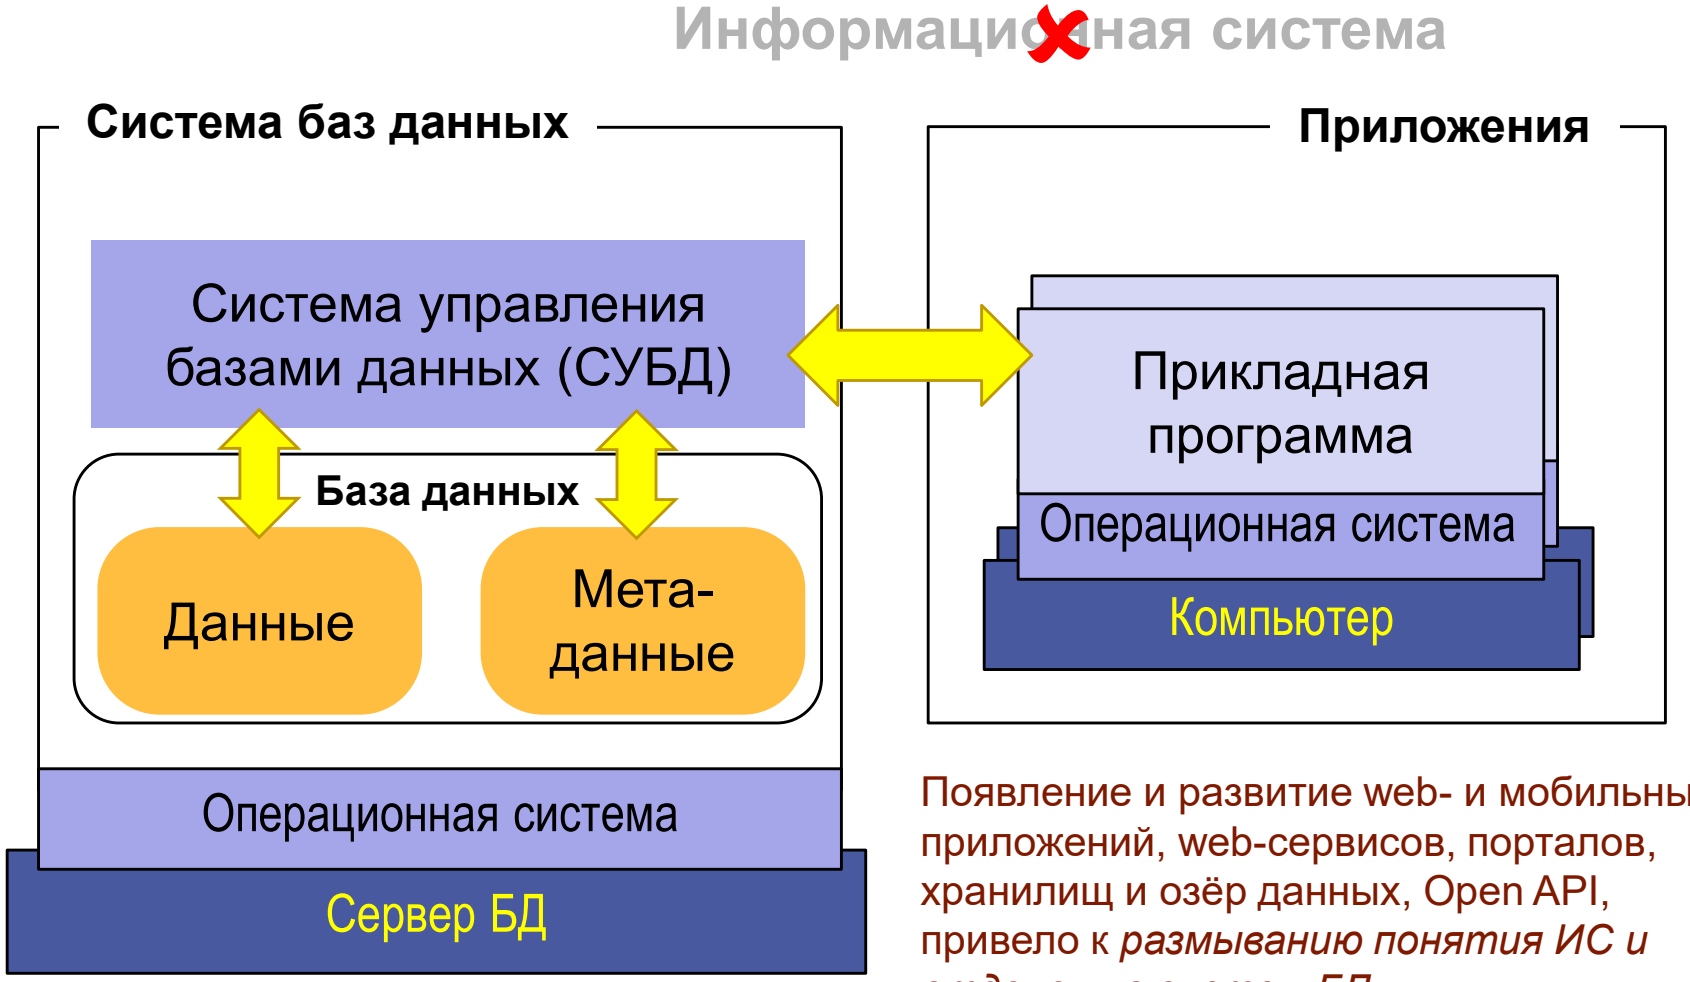

Появление и развитие web- и мобильных приложений, web-сервисов, порталов, хранилищ и озёр данных, Open API, привело к *размыванию понятия ИС и отделению систем БД.*

Датацентричный подход: обособление и обобществление систем БД

Роли в системе БД и приложении

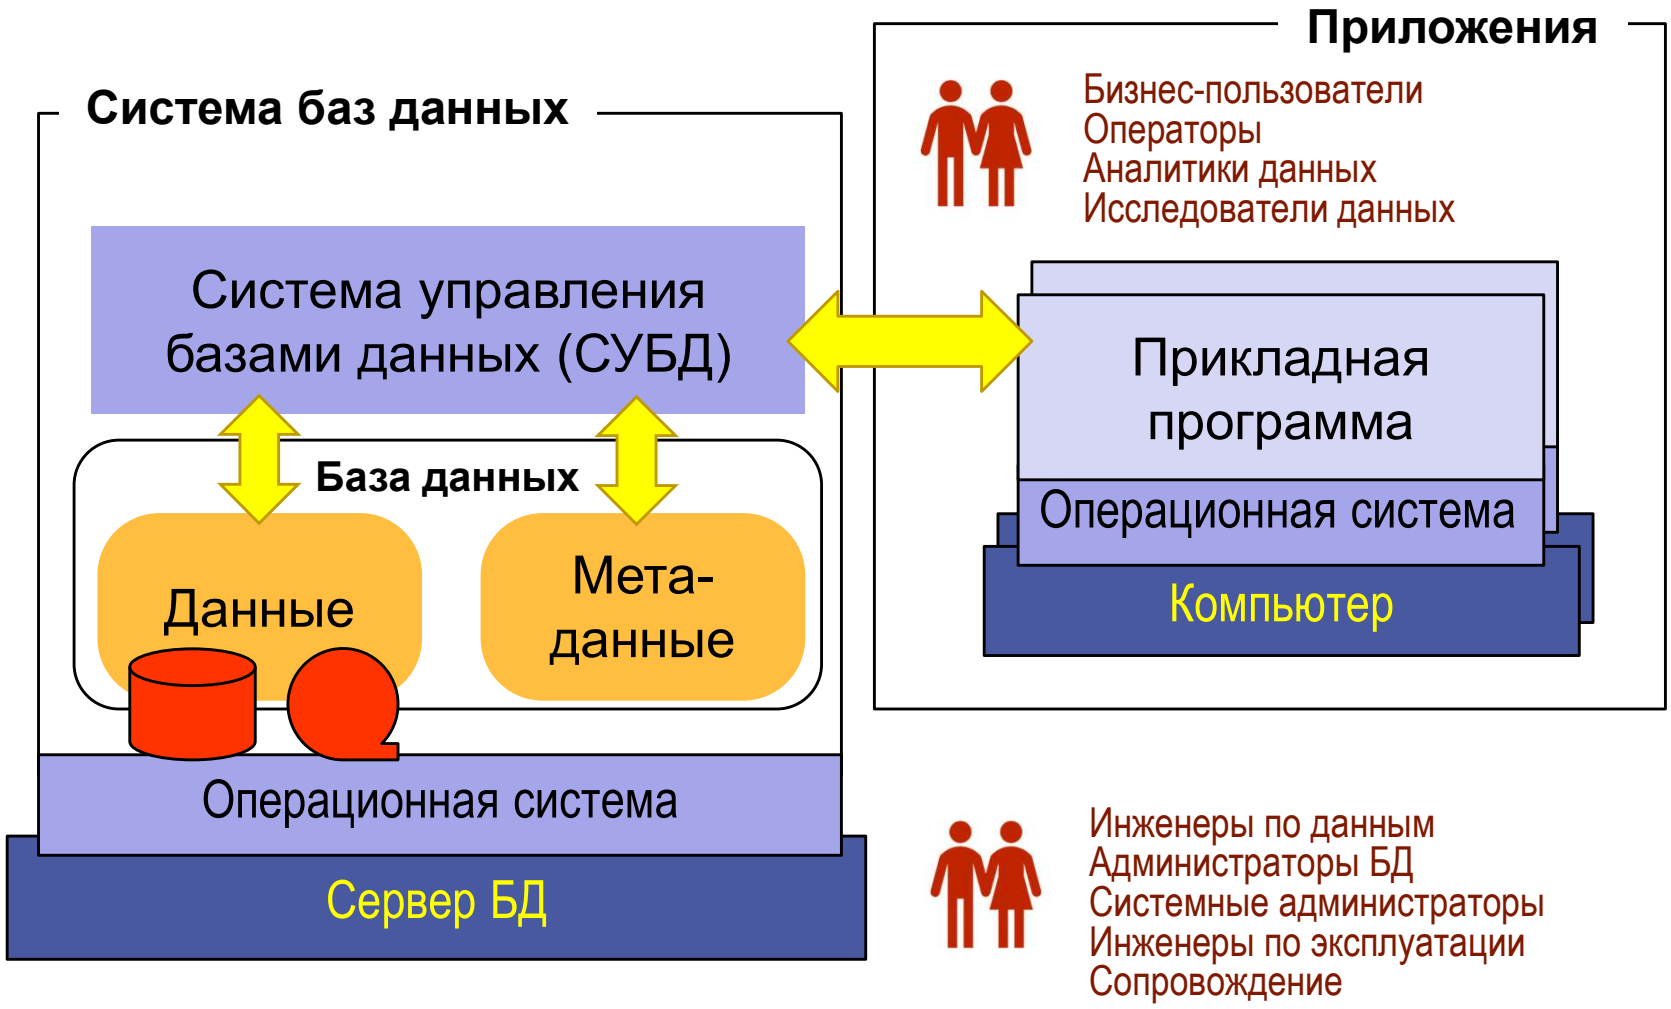

Новые роли: аналитики и исследователи данных, инженеры по данным

Роли при создании БД и приложения

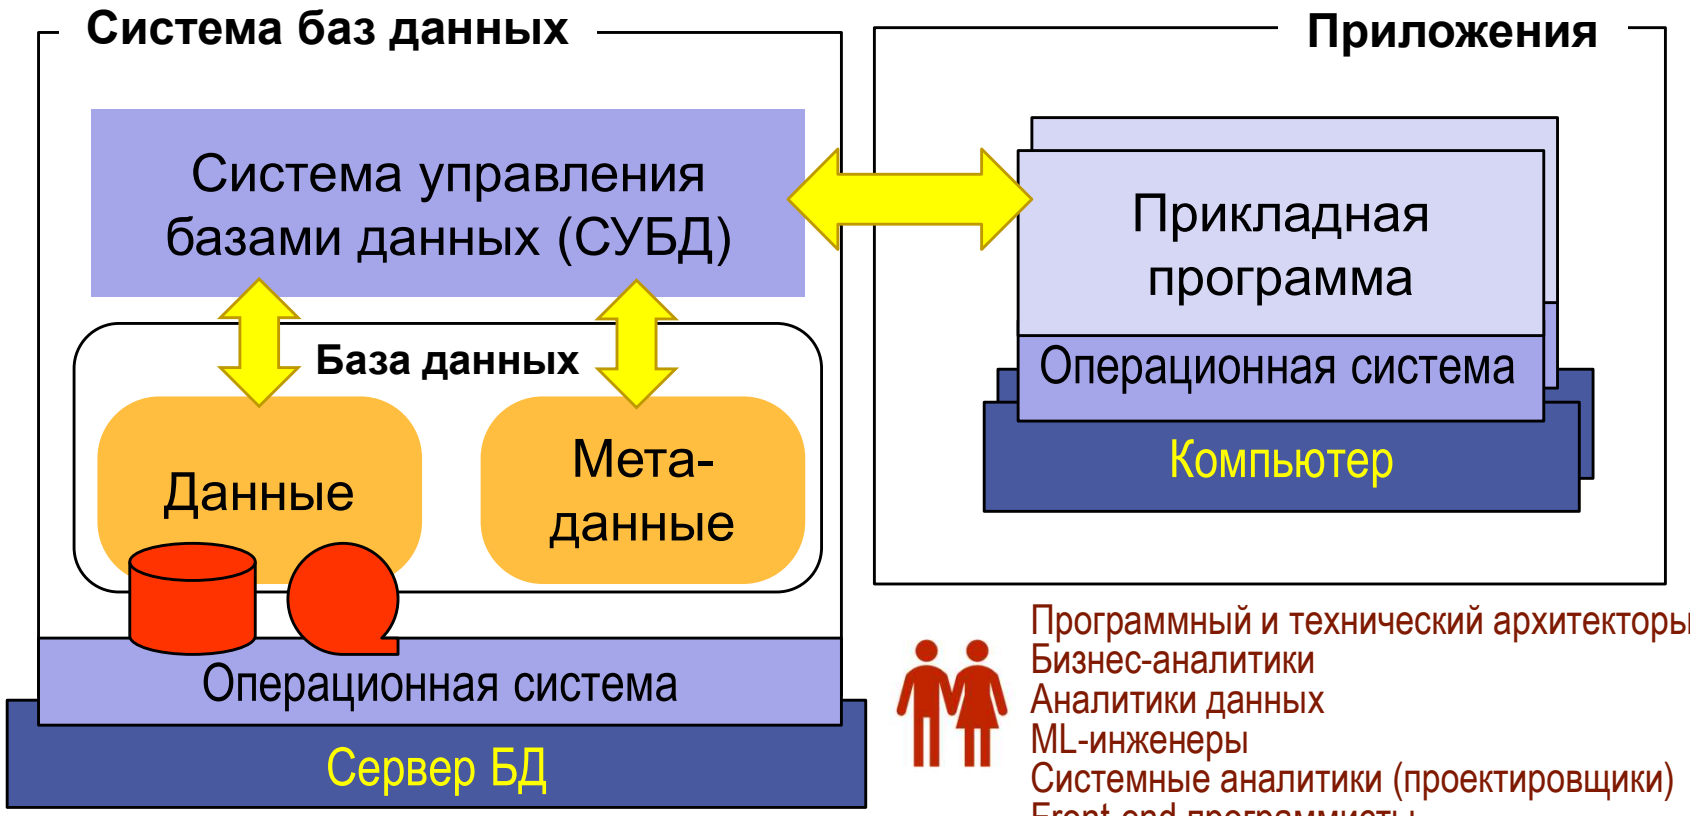

Программный и технический архитекторы
Бизнес-аналитики
Аналитики данных
ML-инженеры
Системные аналитики (проектировщики)
Front-end программисты
GUI-дизайнеры
Тестировщики приложений

Архитектор данных и др. архитекторы
Бизнес-аналитики
Модельеры данных
Проектировщики БД
Инженеры по данным
Back-end программисты
Тестировщики БД

Инструменты, языки программирования, библиотеки и frameworki

Новые роли: аналитики и исследователи данных, инженеры по данным

Бумажные носители данных

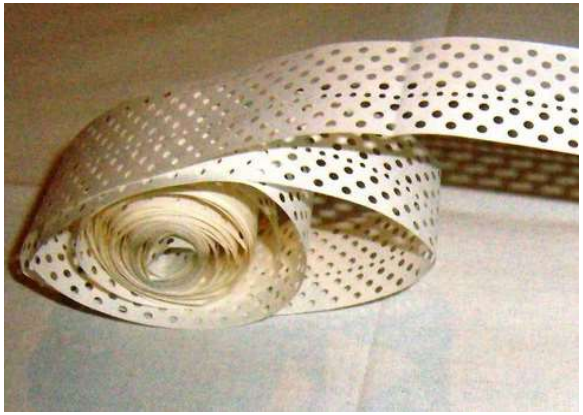

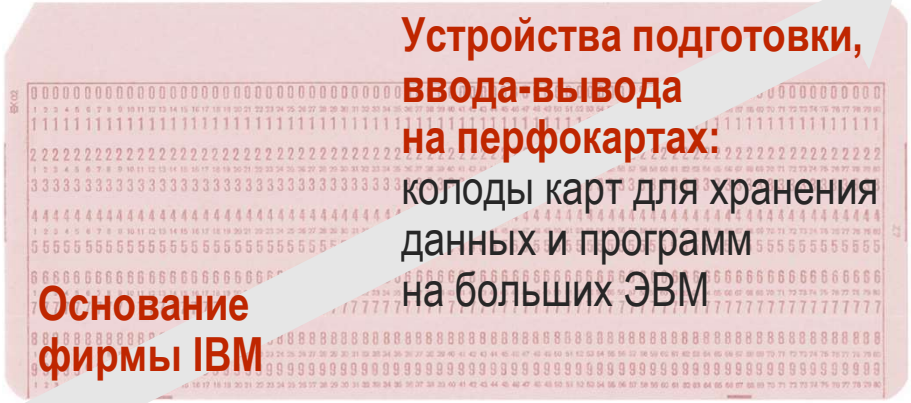

Устройства подготовки, ввода-вывода на перфокартах:
колоды карт для хранения данных и программ на больших ЭВМ

Основание фирмы IBM

Перфокарты:
Ж.М. Жаккард, ткацкий станок

Перфоленты телетайп,
ограниченное применение для ЭВМ

Табуляторы перфокарт:
Г. Холлерит, перепись населения США, 22 т карт, 1 Гб

Счётные, сортирующие и суммирующие табуляторы:
бухучёт, инвентаризация, расчёт зарплаты, планирование и т.п

Ленты перфокарт:
Б. Бушон, Ж.Б.Фалькон, Ж. де Вокансон ткацкие станки и игрушки-роботы

Транспортные карты, учёт работы, шарманка

XVIII в.	1804	1846	1890	1924	1950-е – 1980-е годы	1960-е – 1990-е годы

Электронные носители данных

Магнитная плёнка:
Ф. Пфлюмер

Магнитный барабан:
расширение ОП

Магнитная лента:
ЭВМ UNIVAC I
300 Мб

Жёсткие магнитные диски:
IBM
5 млн символов
сейчас 20 Тб

Магнитная кассета:
Phillips

Гибкий магнитный диск

Дисковые массивы:
RAID

Дисковые массивы:
SAN/FC, NAS

CD-диски

Флэш-память, карты памяти

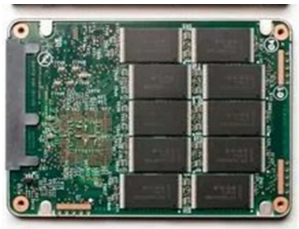

SSD, Израиль

Электронные архивные системы
(кассеты 12 Тб)

DVD-диски

1928	1932	1951	1956	1963	1969	1970-е	1980-е	1984	1995	Кон. 1990-х

Иерархия способов хранения данных

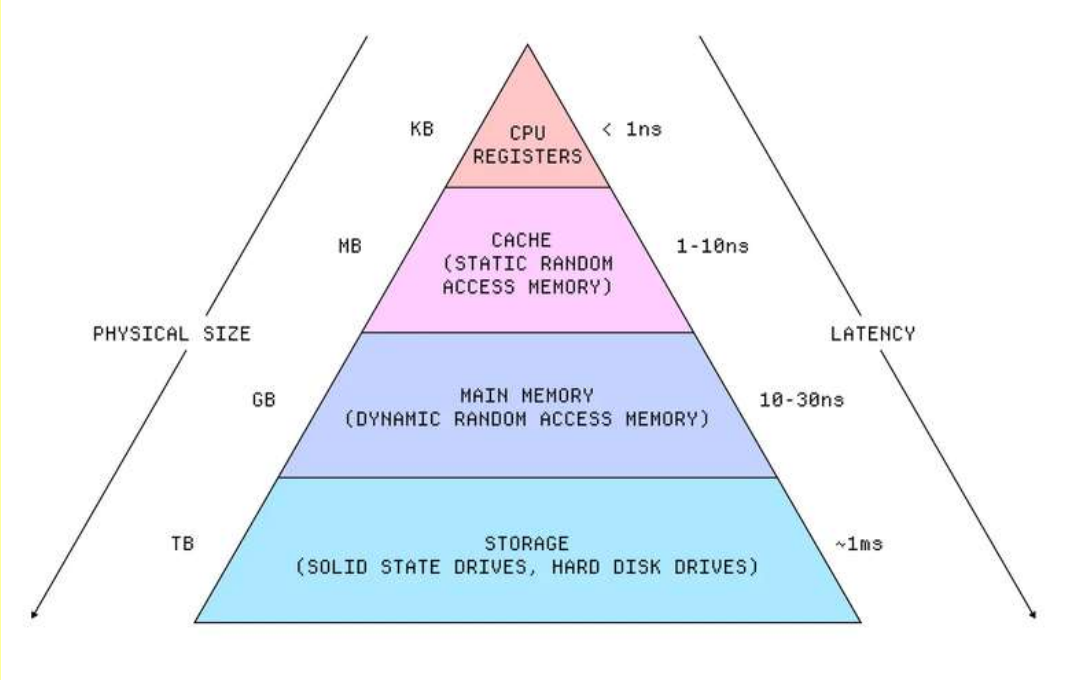
KB
CPU
REGISTERS
< 1ns
MB
CACHE
(STATIC RANDOM
ACCESS MEMORY)
1-10ns
PHYSICAL SIZE
LATENCY
GB
MAIN MEMORY
(DYNAMIC RANDOM ACCESS MEMORY)
10-30ns
TB
STORAGE
(SOLID STATE DRIVES, HARD DISK DRIVES)
~1ms

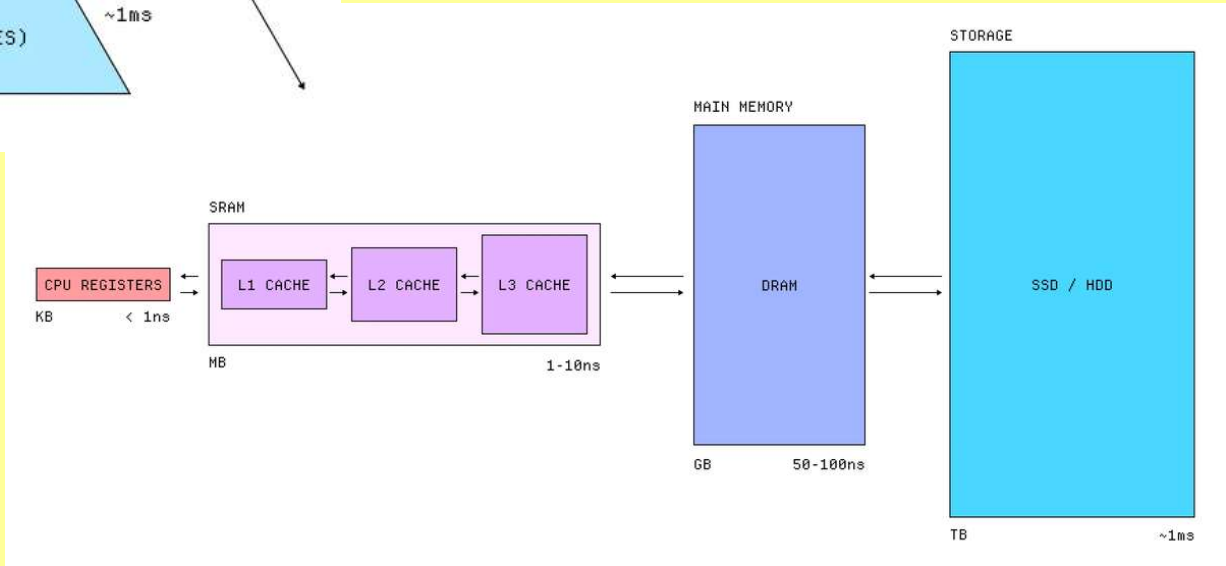
STORAGE
MAIN MEMORY
SRAM
CPU REGISTERS
KB
< 1ns
L1 CACHE
L2 CACHE
L3 CACHE
MB
1-10ns
DRAM
GB
50-100ns
SSD / HDD
TB
~1ms

Исторически сложились 2 направления для работы с данными на ЭВМ

	Виды обработки	Объёмы данных	Структуры данных	Области применения
1	Ввод-вывод и временное хранение данных, *сложные расчёты, двоичная арифметика*	небольшие	простые	Дешифрация, вооружения, физика, космос, математика, инженерия и т.п.
2	Постоянное хранение, поиск, вставка, обновление, удаление данных и *простые расчёты, десятичная арифметика*	относительно большие	средние по сложности и сложные	Перепись населения, бухгалтерский учёт, кадровый учёт, платежи, страхование, библиотеки и т.п.
3	Накопление и аналитическая обработка данных	большие	сложные	Принятие решений, анализ и исследование данных, прогнозирование, машинное обучение, ИИ

Программы–предшественники СУБД

Операции ввода-вывода в FORTRAN
PUNCH / PRINT,
OPEN / CLOSE
READ/ WRITE TAPE,
REWIND, BACKSPACE

1957

COBOL – язык программирования
обработки бизнес-данных

1959

BSAM, BISAM, BDAM –
последовательный,
индексно-последовательный
и прямой методы доступа
к наборам данных в OS/360

IBM RPG –
генератор отчётов
Цикл обработки записей
данных, переквалификация
операторов табуляторов

1964

Утилиты копирования
и сортировки данных

Файловые системы
ОС CTSS и UNIX

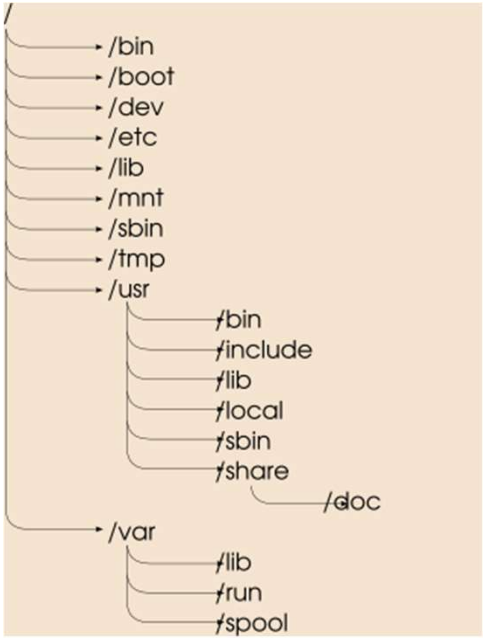

1960-е

1970-е

Язык программирования обработки бизнес-данных COBOL

1959 г.

«*Естественный английский*» язык программирования.

Описание *структуры данных, десятичные числа*.

```
LOOP.
    READ IN-FILE, AT END GOTO EOD.
    ADD AMOUNT TO SUM.
GOTO LOOP.
EOD.
MOVE SUM TO TOTAL-AMOUNT.
CLOSE IN-FILE.
```

Основной язык разработки приложений *для сфер экономики, финансов, гос. управления до начала 1970-х годов*.

До появления магнитных дисков *преобладала последовательная обработка сортированных наборов данных на магнитных лентах*.

Развивается и используется по сей день.
Много унаследованных приложений.
70% банковских транзакций в США.

Создатели: Комитет **CODASYL**, группа фирм, рук. **Грейс Хоппер**, контр-адмирал ВМС США.

Отделение описания данных от обработки

Методы доступа к данным и наборы данных в IBM OS/360

BSAM – базисный последовательный метод доступа к данным

QSAM – последовательный метод доступа к данным с очередями

BISAM – базисный индексно-последовательный метод доступа к данным

QISAM – индексно-последовательный метод доступа к данным с очередями

BPAM – библиотечный метод доступа (2 уровня: библиотеки и модули)

BDAM – прямой (произвольный) метод доступа к данным

Были заложены основы обработки данных на внешних носителях

Развитие этих методов использовано в первых СУБД

Последовательный метод доступа к данным SAM

Последовательная обработка данных

Не сортированные / сортированные записи
Не сблокированные / сблокированные записи B
Форматы фиксированной F и переменной длины V

Поиск записей (N=1000; b=10; q=100)

Записи сортированы?	Записи сблокированы?	Ср. число чтений при поиске		Пример
		одной записи	q записей	
нет	нет	$N/2$	$q*N/2$	500; $50*10^3$
да	нет	$N/2$	$(N+q)/2$	500; 550
нет	да	$[N/b]/2$	$q*[N/b]/2$	50; $5*10^3$
да	да	$[N/b]/2$	$([N/b]+[q/b])/2$	50; 55

Сортировка **была важна при последовательном пакетном поиске.**
Сблокированные записи **увеличивают производительность**

Последовательное (пакетное) обновление записей

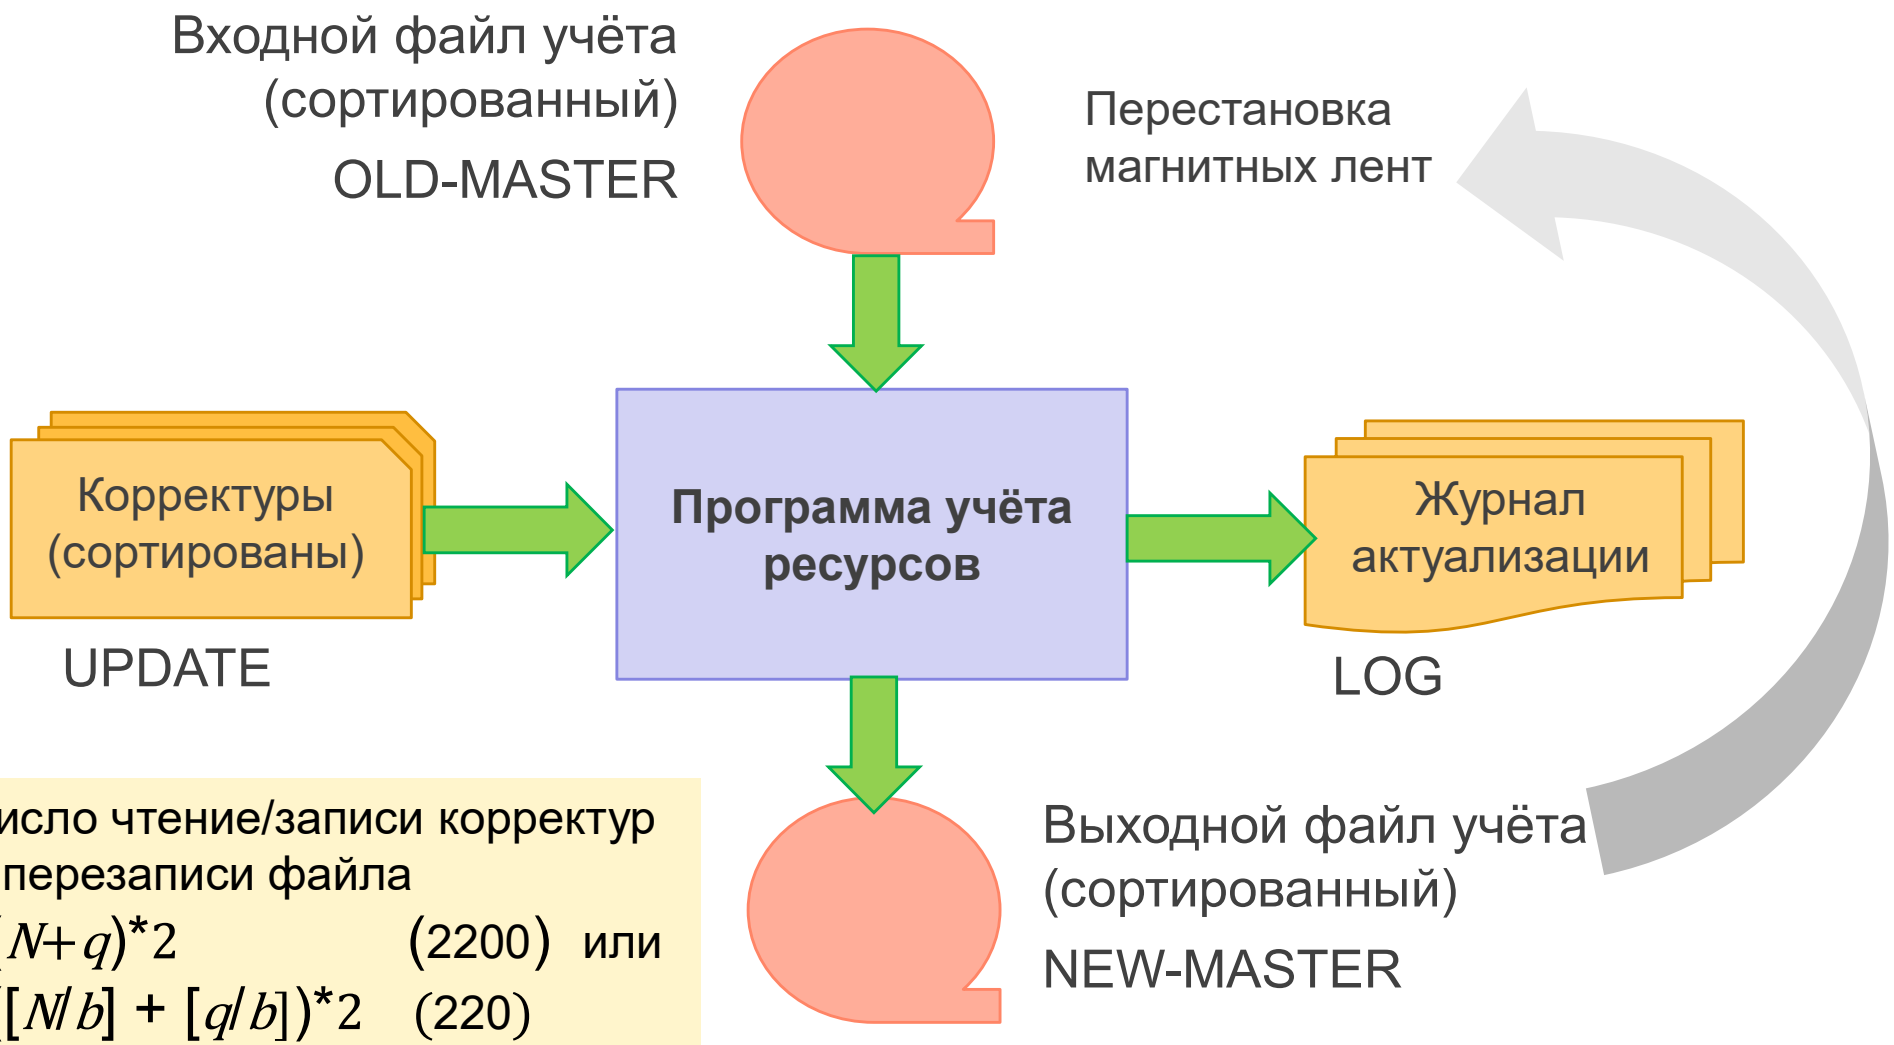

Число чтение/записи корректур и перезаписи файла

$(N+q)*2$ (2200) или

$([N/b] + [q/b])*2$ (220)

Индексно-последовательный метод доступа к данным ISAM

Комбинация последовательного и прямого доступа к *сортированным* данным

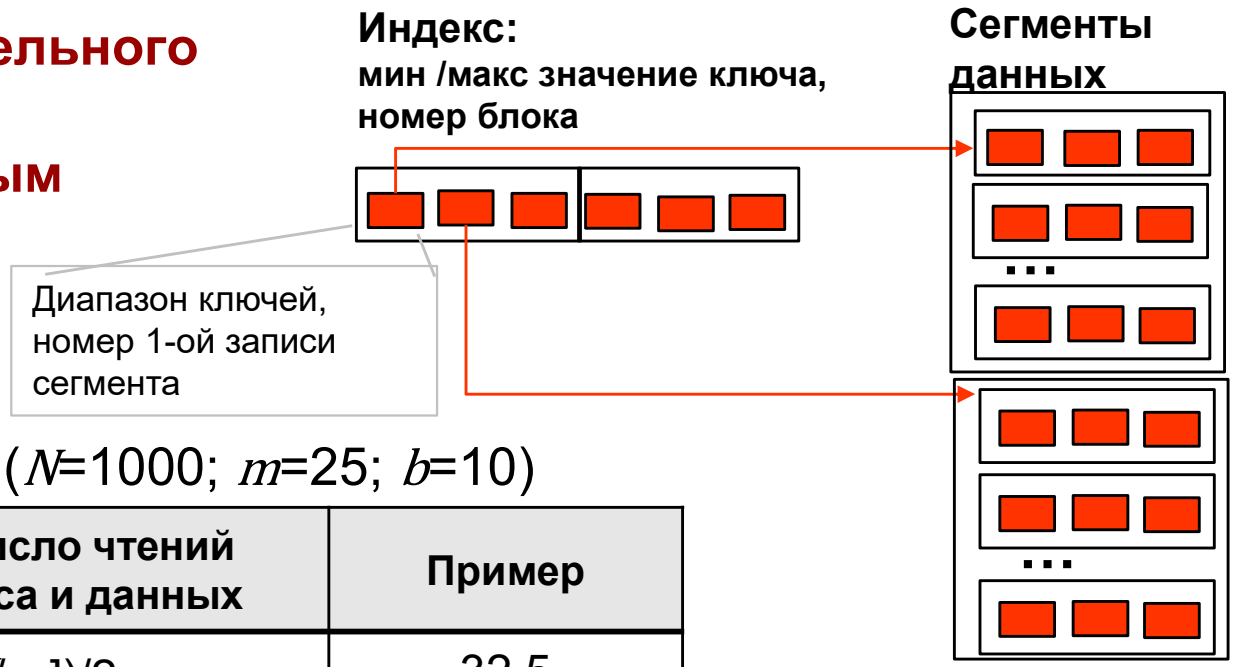

Поиск отдельной записи (N=1000; m=25; b=10)

Записи сблокированы?	Ср. число чтений индекса и данных	Пример
нет	$(m + [N/m])/2$	32,5
да	$([m/b] + [[N/m]/b])/2$	3,5

$$m_{опт} = \sqrt{N}$$

Изменение данных сложнее: от обновления по месту до вставки/ удаления с возможной реорганизацией сегмента и корректировкой индекса

Разработан ещё для пула МЛ, важна сортировка записей.
Актуален для дисков, его модификации используется в СУБД.

Прямой метод доступа к данным

- **К данным на дисках возможен прямой доступ**
- **Проблема соответствия ключа номеру записи**
- **При наличии такого прямого соответствия – получаем разреженные наборы записей**
- **Для плотных наборов записей используют разные способы преобразования:**
  - Хеширование индексы (кластеры)
  - Древовидные индексы, как правило, B-деревья
  - Битовые индексы (по столбцам)
  - Индекс-таблица = индекс + данные

Появление систем управления БД

Персональная СУБД MS Access

Персональная СУБД dBase

РСУБД ORACLE – 1-ая коммерческая, Л. Эллисон

Язык запросов QBE, М. Злуф

Сетевая СУБД IDMS, Cullinane

Сетевая СУБД TOTAL, связанные списки, Cincom,
СУБД ADABAS, инвертированные списки, Software AG

Реляционный подход, Э. Кодд

Иерарх. СУБД IMS, язык DL/1 – комитет CODASYL, IBM

Сетевая СУБД IDS, GE, Ч. Бахман

РСУБД System R, язык SEQUEL-2 – основа SQL, Д.Чемберлин
РСУБД SQL/DS и **DB2 (IBM),**
РСУБД Ingres, язык Quel, UCB, М. Стоунбрекер,

1960-е		1970-е					
	1967	1970	1973	1975	1979	1980	1992

Развитие СУБД

Многомерная СУБД Express

Спец СУБД Tandem Non-Stop (надёжная обработка транзакций)

Мультимодельные СУБД Illustra (объектно-реляционная версия Postgres) → Informix → IBM UDB

Хранилище данных Teradata MPP

OLAP, Э. Кодд, Essbase

Open Source СУБД PostgreSQL

OLAP встроена в Oracle, MS SQL Server, IBM DB2

ПАК хранилищ данных IBM Netezza, Oracle Exadata

СУБД NOSQL: Google, HDFS, MapReduce, BigTable, Hive, HBase, MongoDB

Расширение типов данных и моделей в СУБД

СУБД NewSQL: VoltDB, мод. MySQL, Greenplum

Облачные СУБД SQL/NoSQL: Amazon, MS Azure, Snowflake, Oracle

1970	1980-е	1992	1993	1997	2000-е	2010
		1990-е				

Классификация СУБД

Признаки классификации

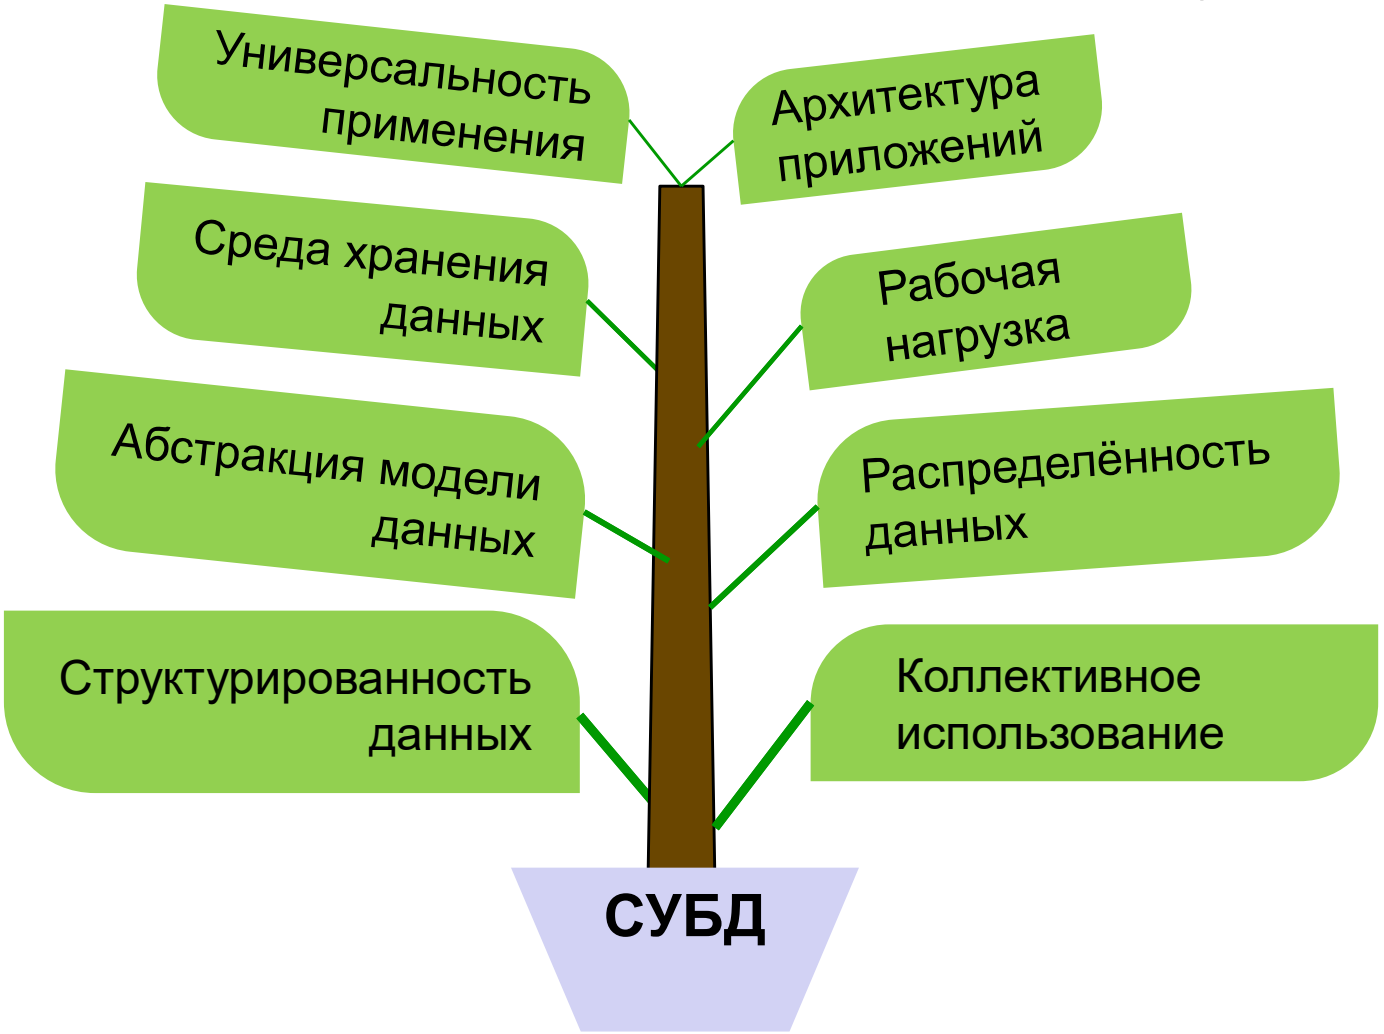

Данные с разной степенью структурированности

	Структурированные данные	Полуструктурированные данные	Неструктурированные данные
Форматы	Таблицы, строки, столбцы, ключи	XML, JSON, CSV, log	Текст, картинки, аудио, видео, гипертекст, геокарты
Абстракция модели данных	Реляционная, многомерная, иерархия, сетевая	Иерархия, граф, плоская таблица	Нет модели данных
Схема данных	Хорошо определённая фиксированная схема	Слабая схема данных	Нет схемы
Хранение данных	Реляционные СУБД, классические хранилища данных (data warehouse)	Нереляционные СУБД (NOSQL)	Файловые системы, озёра данных (data lake), облачные ХД
Методы обработки	SQL-запросы, QBE, BI, data mining, AI	Языки запросов, data mining, AI	NLP, анализ текста, LLM, распознавание образов, анализ аудио и видео

Абстракции модели данных

Иерархические БД	IBM IMS
Сетевые БД	Cullinane IDMS
Реляционные БД (**SQL** и **NewSQL**, построчные и колоночные)	Oracle, MS SQL Server, PostgreSQL, MySQL, Clickhouse, MS Access
Темпоральные (изменения во времени)	MS SQL Server 2016+, PostgreSQL расш.
Объектные и объектно-реляционные БД	Db4o, ObjectStore, ObjectDB

NoSQL	БД «ключ-значение»	Redis, Riak KV, OrientDB, Tarantool
	Документные БД	MongoDB, YDB, Енисей
	Графовые БД	Neo4J, Virtuoso, Memgraph
	БД с семейством колонок	Cassandra, HBase, Azure Cosmos DB
	Поисковые (полнотекстовые) БД	Elasticsearch, Solr, Splunk, Sphinx

Oracle, MS SQL, PostgreSQL+PostGIS, Hiperion, Oracle OLAP, MS Analytical Services	Пространственные БД
Sedna, BaseX, MarkLogic	Многомерные БД (OLAP, BI)
InfluxDB, Prometheus, Graphite, Riak TS	Native XML
Kdb, Pinecone, Chroma, Milvus	БД временных рядов
Jackrabbit, ModeShape	Векторные БД
	Контентные БД (изображения, аудио, видео, гипертекст)

Мультимодельные БД

Возможности СУБД с разными моделями данных

Возможность \ Модель	Реляционная	Графовая	Объектная	Семейство колонок	Документная	Ключ-значение
Поиск по ключу	+	+	+	+	+	+
Извлечение/ обновление части атрибута	+	+	+	+	+	–
Поиск по неключевым атрибутам	+	+	+	+	+	–
Составной ключ	+	+	+	+	–	–
Связи между сущностями	+	+	+	–	–	–
Стандартный интерфейс	+	±	–	–	–	–
Слабоструктурированные данные	+	–	–	+	+	+

Мультимодельные СУБД

СУБД	Изначальная модель	Дополнительные модели
Oracle	Реляционная	Многомерная, графовая, документная, многомерная, пространственная
MS SQL Server	Реляционная	Графовая, документная, многомерная
PostgreSQL	Реляционная	Графовая, документная
MongoDB	Документная	Ключ-значение, графовая
DataStax	Семейство колонок	Документная, графовая
Redis	Ключ-значение	Документная, графовая
Tarantool	—	Реляционная, ключ-значение, документная, пространственная
OrientDB	—	Графовая, документная
Azure CosmosDB	—	Графовая, документная, реляционная

Среды хранения баз данных

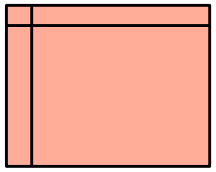

Основная память

базы данных in-memory

Redis, SAP HANA, Oracle Database in-memory, Memcached, Apache Ignate

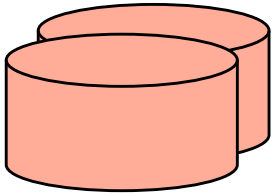

Вторичная память:

магнитные диски, SSD, СХД **–**

базы данных на дисках

Oracle, MS SQL Server, PostgreSQL, MySQL, MS Access

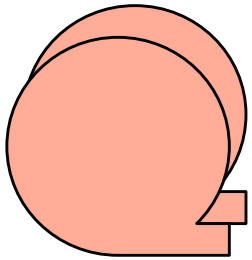

Третичная память:

магнитные кассеты, оптические диски **–**

архивы и резервные копии

не являются БД и с ними СУБД не работают, но они сопутствуют БД и СУБД

Универсальность применения СУБД

Определяется

- возможностями
- мультимодельностью
- характером решаемых задач
- требованиями к безопасности и надёжности
- требованиями к производительности

Различают

- универсальные (общего назначения) СУБД
- специализированные СУБД

Коллективное использование БД

Персональные однопользовательские базы данных и СУБД

Коллективные многопользовательские базы данных и СУБД

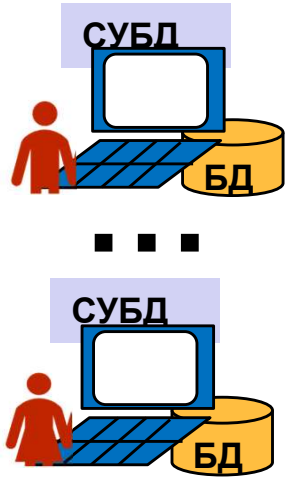

ПК, ноутбуки, планшеты, терминалы, рабочие станции

Локальная / глобальная сеть, Интернет

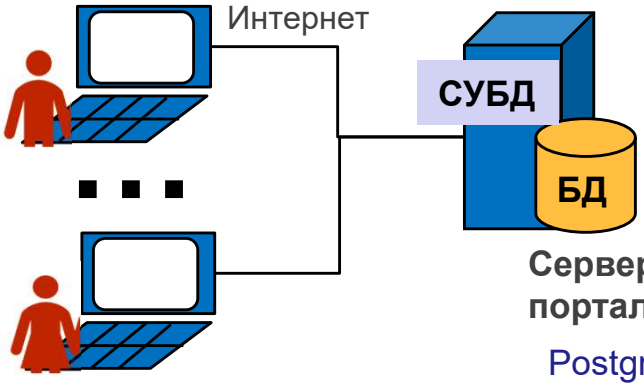

Сервер БД, портал, сайт

PostgreSQL
MySQL
MS SQL Server
Oracle

MS Access
FileMaker
Libre Office Base

Авторизация и права доступа к файлу БД, блокировка файла при изменениях

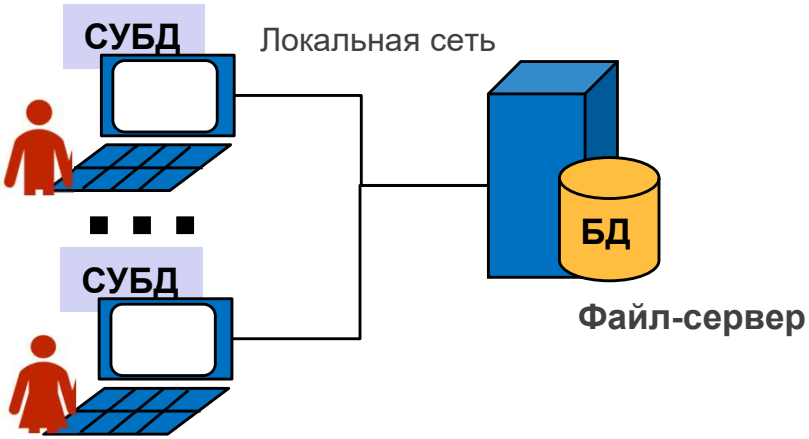

Файл-сервер

Авторизация и права доступа к БД, таблицам, строкам и столбцам. Целостность транзакций. Изоляция обновлений.

Распределённые данные и СУБД

Сосредоточенные БД

- Локальные
- Централизованные

Распределённые БД

- Однородные
- Неоднородные
- Фрагментированные (шардинг)
- Тиражируемые (репликации)

Архитектура приложений

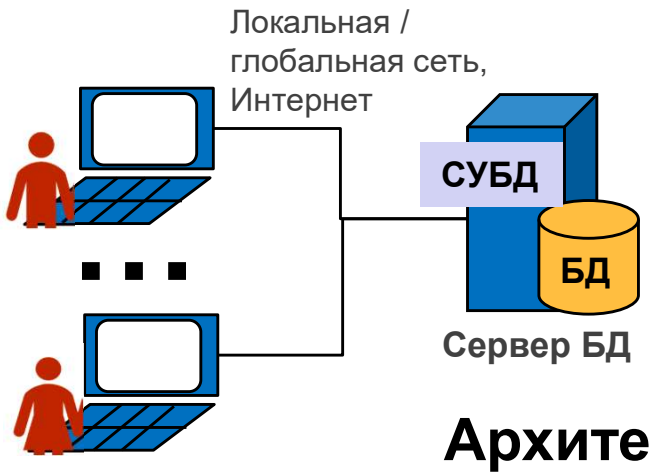

Архитектуры клиент-сервер

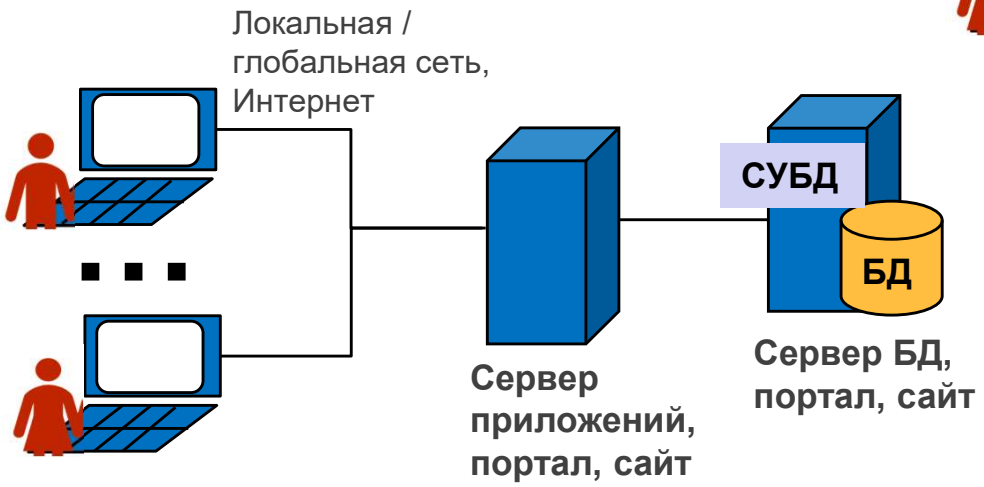

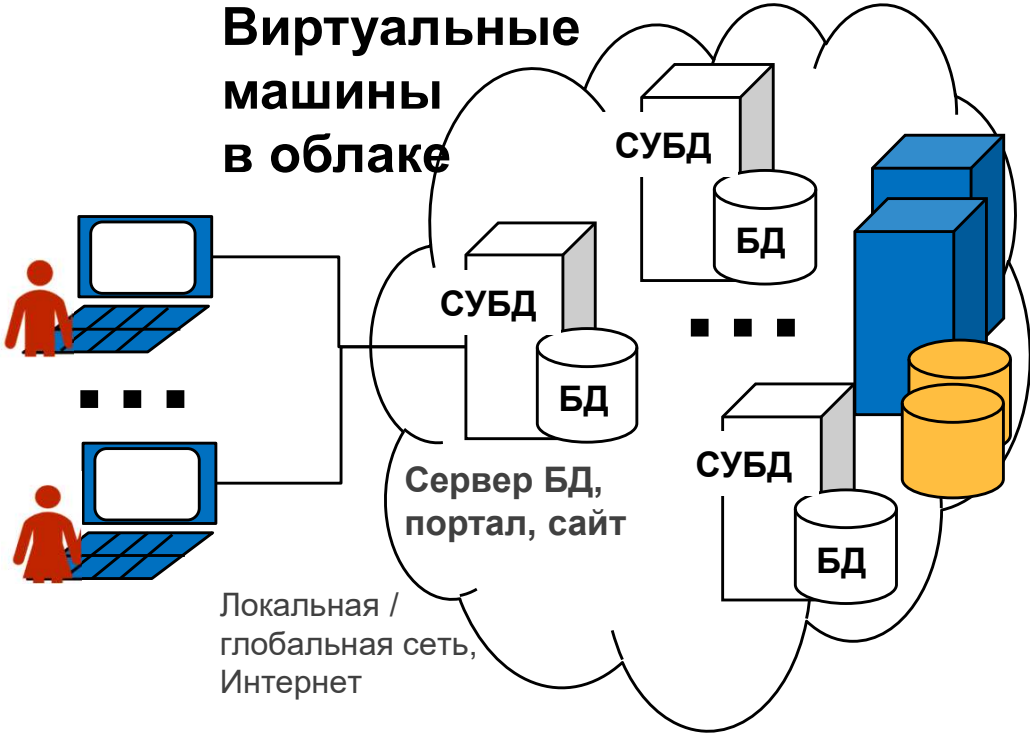

Облачные сервисы:

IaaS – инфраструктура
PaaS – платформа (СУБД)
DbaaS – СУБД + БД

Рабочая нагрузка СУБД

Транзакционная нагрузка OLTP

Высокопроизводительные HP OLTP

Высоконадёжные HA OLTP

Хранилища данных DWH

Поддержка принятия решений OLAP/DSS

Системы искусственного интеллекта AI / ML

Мультимедийная нагрузка

Рейтинг современных СУБД

DB-Engines Ranking

429 systems in ranking, January 2026

Rank			DBMS	Database Model	Score		
Jan 2026	Dec 2025	Jan 2025			Jan 2026	Dec 2025	Jan 2025
1.	1.	1.	Oracle	Relational, Multi-model	1237.34	+2.94	-21.42
2.	2.	2.	MySQL	Relational, Multi-model	867.52	-0.97	-130.63
3.	3.	3.	Microsoft SQL Server	Relational, Multi-model	706.26	-16.26	-92.30
4.	4.	4.	PostgreSQL	Relational, Multi-model	666.27	+6.84	+2.86
5.	5.	5.	MongoDB	Multi-model	376.74	+4.46	-25.77
6.	6.	6.	Snowflake	Relational	207.79	+5.34	+53.89
7.	7.	7.	Redis	Key-value, Multi-model	144.16	+1.68	-9.20
8.	8.	↑ 13.	Databricks	Multi-model	141.55	+3.53	+53.70
9.	9.	9.	IBM Db2	Relational, Multi-model	112.72	-3.04	-10.25
10.	10.	↓ 8.	Elasticsearch	Multi-model	107.15	-2.68	-27.78

12 Open Source СУБД в 2025 году

Database Management system	Data model	Requirements	Best for
MySQL	SQL	High read/write throughput	Web apps, CMS, eCommerce
PostgreSQL	SQL	Complex queries, advanced indexing	GIS, financial services, analytics
MariaDB	SQL	Transactional + analytical workloads	MySQL replacement
MongoDB	NoSQL	Real-time queries, flexible schema	IoT, content management
SQLite	SQL	Lightweight, embedded use	Mobile apps, desktop tools
CockroachDB	SQL	Strong consistency	Multi-region SaaS
Redis	NoSQL	Sub-millisecond latency	Caching, real-time analytics
CouchDB	NoSQL	Offline sync, RESTful API	IoT, distributed mobile apps
Neo4j	NoSQL	Relationship traversal, deep joins	Social networks, fraud detection
FirebirdSQL	SQL	OLTP + OLAP concurrency	Embedded systems, SMB apps
OrientDB	SQL	Fast traversal, flexible schema	Identity management, recommendation engines
Cassandra	NoSQL	High write throughput, linear scalability	Time-series, event

Выводы

БД = хранимые данные + метаданные + контейнеры
СУБД – системное ПО для создания, ведения и совместного использования БД через программные и языковые интерфейсы
Система БД = БД + СУБД + системно-техническая инфраструктура
Топ 10 рейтинга DB-Engines: 3 закрытых СУБД (Oracle, MS SQL, IBM Db2), 6 Open Source (MySQL, PostgreSQL и др.), 6 реляционных и 9 мультимодельных, 2 облачные.

Иерархия способов хранения данных

Классификация СУБД и БД

Терпения и удачи всем, кто связан с базами данных

Спасибо за внимание!

Валерий Иванович Артемьев

МГТУ имени Н.Э. Баумана, кафедра ИУ-5

Банк России
Департамент *данных*, проектов и процессов

Тел.: +7(495) 753-96-25
e-mail: viart@bmstu.ru