Базы данных

А5. Анализ данных на языке SQL

Московский государственный технический университет
имени Н.Э. Баумана

Факультет ИБМ

Мар 2025 года

Москва

Артемьев Валерий Иванович © 2025

Запросы «на лету» и отчёты

Электронные таблицы

MS Excel

- Импорт таблиц БД
- Умные таблицы
- QBE (формы, фильтры)
- Структуры с уровнями
- SQL (через Power Query)

Инструменты SQL

Microsoft Access

- QBE (конструктор запросов, формы поиска)
- SQL (запросы, **агрегаты,** фильтры, сортировка)
- Конструктор отчётов

Средства бизнес-аналитики BI

DataLens

Apache Superset

Power BI Desktop

tableau Public

- Отчёты
- Запросы «на лету»
- Интерактивный анализ данных OLAP

Языковые среды Python, R

- SQL-запросы к БД
- Работа с фреймами данных
- Визуализация данных
- Машинное обучение

Интерактивный анализ данных

Электронные таблицы

MS Excel

- Умные таблицы
- Сводные таблицы
- Power Pivot

Инструменты SQL

Microsoft Access

- QBE (конструктор запросов, формы поиска)
- SQL (запросы, **агрегаты,** фильтры, сортировка)
- Сводные таблицы
- SQL PIVOT / UNPIVOT

Средства бизнес-аналитики BI

DataLens

Apache Superset

Power BI Desktop

tableau Public

- Запросы «на лету»
- Интерактивный анализ данных OLAP
- Разведочный анализ данных (EDA)

Языковые среды Python, R

- SQL-запросы к БД
- Работа с фреймами данных
- Визуализация данных
- Машинное обучение

Визуализация данных и панели мониторинга

Электронные таблицы

MS Excel

- Сводные таблицы
- Формы
- Сводные диаграммы
- Power Pivot

Инструменты SQL

Microsoft Access

- Сводные таблицы
- Формы
- Диаграммы

Средства бизнес-аналитики BI

DataLens

Apache Superset

Power BI Desktop

tableau Public

- Отчёты
- Запросы «на лету»
- Интерактивный анализ данных (OLAP)
- Панели мониторинга (dashboard)
- Разведочный анализ данных (EDA)

Языковые среды Python, R

- SQL-запросы к БД
- Работа с фреймами данных
- Визуализация данных
- Машинное обучение

Визуализация данных и панели мониторинга

MS Excel

- Сводные таблицы
- Формы
- Сводные диаграммы
- Power Pivot

Microsoft Access

- Сводные таблицы
- Формы
- Диаграммы

Средства бизнес-аналитики BI

Apache Superset

Metabase

Power BI Desktop

Qlik Sense Personal

tableau Public

DataLens

- Отчёты
- Запросы «на лету»
- Интерактивный анализ данных (OLAP)
- Панели мониторинга (dashboard)
- Разведочный анализ данных (EDA)

Агрегирование данных GROUP BY ★

Элементы вывода запроса SELECT, содержащие выражения с *агрегатными функциями*, вычисляются и *группируются* по неагрегированным полям из списка GROUP BY.

Агрегатные функции SQL:

- Count(*выражение*) подсчёт значений без NULL
- Sum(*выражение*) сумма значений
- Avg(*выражение*) среднее значение
- Min, Max(*выражение*) минимум / максимум

SELECT DISTINCT *элементы вывода с агрегатами*
FROM *таблица*
WHERE *условия фильтрации*
GROUP BY *список полей для группировки*
HAVING *фильтр с агрегатами*
ORDER BY *список элементов сортировки*
LIMIT *количество записей*

Примеры агрегирования данных (1)

- Для анализа важно сформулировать *показатели или KPI*
- Назовите, какие показатели важны для управления кадрами
- Нужно понимать, *как считать эти метрики*
- Часто метрики определяются *путём агрегирования*
- Существуют *абсолютные и относительные метрики*
- *Одиночные показатели или распределения*
- Распределения *дискретные или непрерывные*
- Результаты в виде *обычных или сводных таблиц*
- Результаты в виде *диаграмм и графиков*

Примеры агрегирования данных (2)

Определение численности сотрудников:

- общей
- по полу
- по образованию

Минимальный, средний и максимальный:

- возраст сотрудника
- стаж работы

Доля сотрудников:

- женщин
- с высшим образованием
- пенсионеров

Распределение сотрудников:

- по возрасту
- по стажу
- по возрасту-полу
- по стажу-полу

Определение численности (1)

SELECT COUNT(*) AS [Всего сотрудников]
FROM СОТРУДНИКИ;

31 Общее число сотрудников

Всего сотрудников
11

Определите, сколько мужчин на предприятии

Определение численности (2)

```
SELECT COUNT(*) AS [Всего сотрудников]
FROM СОТРУДНИКИ;
```

31 Общее число сотрудников

Всего сотрудников
11

```
SELECT COUNT(Пол) AS [Всего мужчин]
FROM СОТРУДНИКИ
WHERE Пол="М";
```

32 Сколько мужчин

Всего мужчин
7

Расчёт численности в разрезе (1)

```
SELECT Пол, COUNT(Пол) AS [Кол-во]
FROM СОТРУДНИКИ
GROUP BY Пол;
```

33 Распределение по полу

Пол	Кол-во
Ж	4
М	7

Рассчитайте численность в разрезе образования

Расчёт численности в разрезе (2)

```
SELECT Пол, COUNT(Пол) AS [Кол-во]
FROM СОТРУДНИКИ
GROUP BY Пол;
```

33 Распределение по полу

Пол	Кол-во
Ж	4
М	7

```
SELECT Образование,
COUNT(Образование) AS [Кол-во]
FROM СОТРУДНИКИ
GROUP BY Образование;
```

34 Распределение по образованию

Образование	Кол-во
высшее	4
среднее	5
среднее специальное	2

Расчёт численности в 2-х разрезах (1)

SELECT Пол, Образование, COUNT(Образование) AS [Кол-во]
FROM СОТРУДНИКИ GROUP BY Пол, Образование;

35 Распределение пол-образование

Пол	Образование	Кол-во
Ж	высшее	2
Ж	среднее	1
Ж	среднее специальное	1
М	высшее	2
М	среднее	4
М	среднее специальное	1

Постройте приведённую ниже сводную таблицу, используя суммирование SUM условий по полу с помощью функции ЕСЛИ, например IIF(Пол="М",1,0).

35а Распределение образование-пол (усл сумма)

Образование	Мужчины	Женщины
высшее	2	2
среднее	4	1
среднее специальное	1	1

Расчёт численности в виде сводной таблицы для 2-х разрезов

```
SELECT Пол, Образование,
COUNT(Образование) AS [Кол-во]
FROM СОТРУДНИКИ GROUP BY Пол, Образование;
```

35 Распределение пол-образование

Пол	Образование	Кол-во
Ж	высшее	2
Ж	среднее	1
Ж	среднее специальное	1
М	высшее	2
М	среднее	4
М	среднее специальное	1

```
SELECT Образование,
SUM(IIF(Пол="М",1,0)) AS Мужчины,
SUM(IIF(Пол="Ж",1,0)) AS Женщины
FROM СОТРУДНИКИ GROUP BY Образование;
```

35а Распределение образование-пол (усл сумма)

Образование	Мужчины	Женщины
высшее	2	2
среднее	4	1
среднее специальное	1	1

Трюк для расчёта численности в виде сводной таблицы (1)

Для подсчёта количества по какому либо признаку атрибута можно использовать суммирование условий равенства атрибута этому признаку. Нужно только учитывать, что в MS Access ИСТИНА равна -1.

```
SELECT Образование,
SUM(-(Пол="М")) AS Мужчины,
SUM(-(Пол="Ж")) AS Женщины
FROM СОТРУДНИКИ
GROUP BY Образование;
```

```
SELECT Образование,
-SUM(Пол="М") AS Мужчины,
-SUM(Пол="Ж") AS Женщины
FROM СОТРУДНИКИ
GROUP BY Образование;
```

35а Распределение образование-пол (усл сумма)

Образование	Мужчины	Женщины
высшее	2	2
среднее	4	1
среднее специальное	1	1

Добавьте столбец итога в сводную таблицу

Трюк для расчёта численности в виде сводной таблицы (2)

```
SELECT Образование,
-SUM(Пол="М") AS Мужчины,
-SUM(Пол="Ж") AS Женщины
FROM СОТРУДНИКИ
GROUP BY Образование;
```

35а Распределение образование-пол (усл сумма)

Образование	Мужчины	Женщины
высшее	2	2
среднее	4	1
среднее специальное	1	1

```
SELECT Образование,
SUM(-(Пол="М")) AS Мужчины,
SUM(-(Пол="Ж")) AS Женщины,
COUNT(Образование) AS Итого
FROM СОТРУДНИКИ GROUP BY Образование;
```

35г Распределение образование-пол с итогом

Образование	Мужчины	Женщины	Итого
высшее	2	2	4
среднее	4	1	5
среднее специальное	1	1	2

Построение таблицы распределения для гистограммы с подзапросом (1)

Для распределения непрерывных величин (возраст, стаж) надо определять диапазоны, куда входят эти величины.

Для возрастных групп по 10 лет надо в MS Access вычислять:

Round(DateDiff("yyyy", [Дата рождения], Now)/10)*10.

В других СУБД работает округление:

Round(DateDiff("yyyy", [Дата рождения], Now)/10, -1)

Решая в лоб, получим:

```
SELECT Round(DateDiff("yyyy", [Дата рождения], Now)/10)*10 &"-летние" AS Возраст,
COUNT(Round(DateDiff("yyyy", [Дата рождения], Now)/10)*10) AS [Кол-во]
FROM СОТРУДНИКИ
GROUP BY Round(DateDiff("yyyy", [Дата рождения], Now)/10)*10;
```

37а Распределение по возрастным группам

Возраст	Кол-во
20-летние	1
30-летние	1
40-летние	3
50-летние	2
60-летние	4

Как устранить этот кошмар?

Дополнительные вычисления при анализе данных

Объединения строк UNION

Итоги по столбцам

Доли (проценты) по строкам и по столбцам

Объединение строк UNION

Инструкции UNION объединяют по строкам результаты двух и более запросов SELECT, обеспечивающих *промежуточные и общие итоги*, а также «склеивают» строки таблиц с одинаковым или почти одинаковым составом полей.

1-ая инструкция **SELECT**
UNION
2-ая инструкция **SELECT**
…
UNION
N-ая инструкция **SELECT**

Пример 1. Расчёт итогов численности по столбцам

```
SELECT Образование, -SUM(Пол="М") AS Мужчины,
-SUM(Пол="Ж") AS Женщины, COUNT(Образование) AS Итого
FROM СОТРУДНИКИ GROUP BY Образование
UNION
SELECT " Всего", -SUM(Пол="М"), -SUM(Пол="Ж"), COUNT(*)
FROM СОТРУДНИКИ ORDER BY 1 DESC;
```

35д Распределение образование-пол с итогами (UNION)

Образовани	Мужчины	Женщины	Итого
среднее специ	1	1	2
среднее	4	1	5
высшее	2	2	4
Итого	7	4	11

Пример 2. Расчёт долей (процентов) по столбцам

```
SELECT Образование, -SUM(Пол="М") AS Мужчины,
    -SUM(Пол="Ж") AS Женщины
FROM СОТРУДНИКИ GROUP BY Образование
UNION
SELECT " Доля", -Round(SUM(Пол="М")/COUNT(*),3)*100&"%",
    - Round(SUM(Пол="Ж")/COUNT(*) ,3)*100&"%
FROM СОТРУДНИКИ ORDER BY 1 DESC;
```

35д Итоговые доли в процентах

Образование	Мужчины	Женщины
Доля	63,6%	36,4%
высшее	2	2
среднее	4	1
среднее специальное	1	1

Построение таблицы распределения для гистограммы с подзапросом (2)

Сначала построим подзапрос, который формирует таблицу с одним столбцом группы возраста:

```
SELECT  Round(DateDiff("yyyy", [Дата рождения], Now)/10)*10
AS ВозрастГруппа  FROM СОТРУДНИКИ
```

И уже из этой таблицы будем строить распределение:

```
SELECT ВозрастГруппа &"-летние" AS Возраст,
COUNT(ВозрастГруппа) AS [Кол-во]
FROM  (SELECT Round(DateDiff("yyyy", [Дата рождения], Now)/10)*10 AS ВозрастГруппа
FROM СОТРУДНИКИ)  AS Группы
GROUP BY ВозрастГруппа;
```

37а Распределение по возрастным группам

Возраст	Кол-во
20-летние	1
30-летние	1
40-летние	3
50-летние	2
60-летние	4

Таблица распределения для гистограммы с несколькими разрезами (1)

Запрос для распределения пол – возраст с подзапросом:

```
SELECT Пол, ВозрастГруппа &"-летние" AS Возраст,
COUNT(ВозрастГруппа) AS [Кол-во]
FROM
(SELECT Пол, Round(DateDiff("yyyy", [Дата рождения], Now)/10)*10 AS
ВозрастГруппа FROM СОТРУДНИКИ)  AS Пол_Возраст
GROUP BY Пол, ВозрастГруппа;
```

38 Распределение пол-возраст

Пол	Возраст	Кол-во
Ж	30-летние	1
Ж	50-летние	1
Ж	60-летние	2
М	20-летние	1
М	40-летние	3
М	50-летние	1
М	60-летние	2

Постройте распределение возраст - пол - образование

Таблица распределения для гистограммы с несколькими разрезами (2)

```
SELECT ВозрастГруппа &"-летние" AS Возраст,  Пол, Образование,
COUNT(ВозрастГруппа) AS [Кол-во]
FROM
(SELECT Образование, Пол, Round(DateDiff("yyyy", [Дата рождения], Now)/10)*10 AS
ВозрастГруппа FROM СОТРУДНИКИ)  AS Группы
GROUP BY ВозрастГруппа, Пол, Образование
ORDER BY ВозрастГруппа, Пол, Образование;
```

39 Распределение возраст-пол-образование

Возраст	Пол	Образование	Кол-во
20-летние	М	среднее	1
30-летние	Ж	высшее	1
40-летние	М	высшее	1
40-летние	М	среднее	2
50-летние	Ж	высшее	1
50-летние	М	среднее специальное	1
60-летние	Ж	среднее	1
60-летние	Ж	среднее специальное	1
60-летние	М	высшее	1
60-летние	М	среднее	1

Постройте распределение по стажу с подзапросом

Таблица распределения численности по стажу работы

```
SELECT "от " & СтажГруппа &" лет" AS Стаж,
COUNT(СтажГруппа) AS [Кол-во]
FROM
    (SELECT Round(DateDiff("yyyy", [Дата приёма], Now)/10)*10 AS СтажГруппа
     FROM СОТРУДНИКИ) AS Группы
GROUP BY СтажГруппа
ORDER BY СтажГруппа;
```

40 Распределение по стажу работы

Стаж	Кол-во
от 10 лет	4
от 20 лет	3
от 30 лет	3
от 40 лет	1

Постройте распределение стаж - пол с подзапросом

Таблица распределения численности по стажу и полу

```
SELECT "от " & СтажГруппа &" лет" AS Стаж, Пол,
COUNT(СтажГруппа) AS [Кол-во]
FROM
    (SELECT
            Round(DateDiff("yyyy", [Дата приёма], Now)/10)*10 AS СтажГруппа,
            Пол
     FROM СОТРУДНИКИ)
GROUP BY СтажГруппа, Пол
ORDER BY СтажГруппа, Пол;
```

41 Распределение стаж-пол

Стаж	Пол	Кол-во
от 10 лет	Ж	2
от 30 лет	Ж	1
от 40 лет	Ж	1
от 10 лет	М	2
от 20 лет	М	3
от 30 лет	М	2

Таблица распределения численности по стажу, полу и образованию

```
SELECT "от "& СтажГруппа &" лет" AS Стаж,
            Пол, Образование,
            COUNT(СтажГруппа) AS [Кол-во]
FROM
    (SELECT Образование, Пол,
                Round(DateDiff("yyyy", [Дата приёма], Now)/10)*10 AS СтажГруппа
     FROM СОТРУДНИКИ)  AS Группы
GROUP BY СтажГруппа, Пол, Образование
ORDER BY СтажГруппа, Пол, Образование;
```

42 Распределение стаж-пол-образование

Стаж	Пол	Образование	Кол-во
от 10 лет	Ж	высшее	1
от 10 лет	Ж	среднее специальное	1
от 10 лет	М	среднее	2
от 20 лет	М	высшее	1
от 20 лет	М	среднее	2
от 30 лет	Ж	высшее	1
от 30 лет	М	высшее	1
от 30 лет	М	среднее специальное	1
от 40 лет	Ж	среднее	1

Вычислите и выведите важные показатели управления кадрами

Вычисление резюме с важными показателями управления кадрами

```
SELECT
    Count([Сотрудник_ид])                                  AS Численность,
    Round(Year(Now)-AVG(Year([Дата рождения])), 1)  AS [Средний возраст],
    Round(Year(Now)-AVG(Year([Дата приёма])), 1)     AS [Средний стаж работы],
    -SUM(Пенсионер)                                         AS [Наличие пенсионеров],
    -Round(SUM(Образование="высшее")/COUNT(*), 3)
                                                        AS [Доля с высшем образованием]
FROM СОТРУДНИКИ;
```

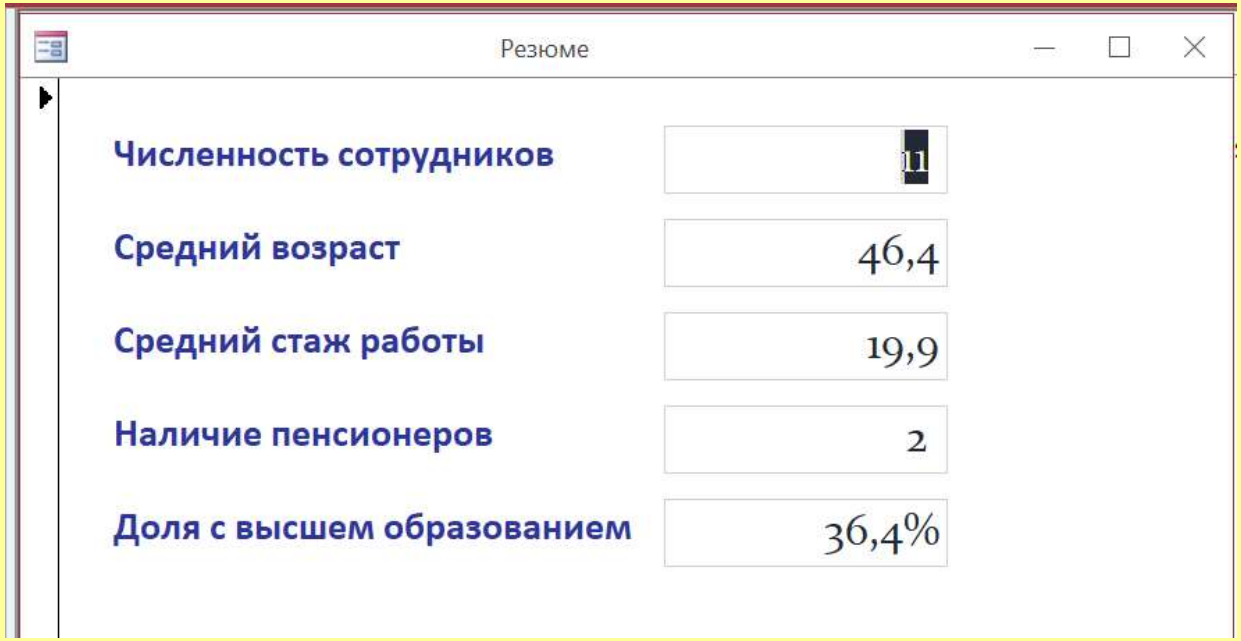

Пример вывода ключевых данных по управлению кадрами

Microsoft Access

Резюме

Численность сотрудников	11
Средний возраст	46,4
Средний стаж работы	19,9
Наличие пенсионеров	2
Доля с высшем образованием	36,4%

Распределение по полу

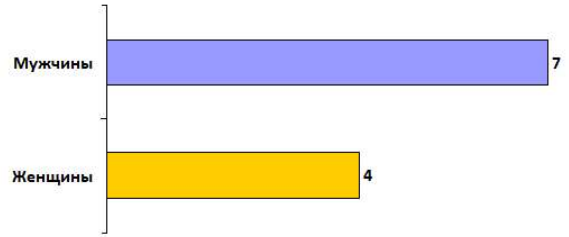

Диаграмма распределения по возрасту2

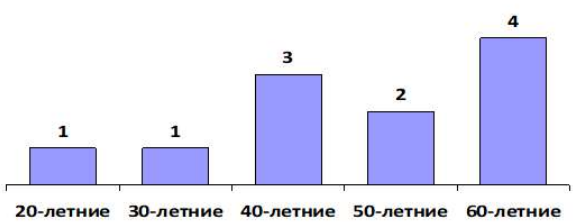

Диаграмма стаж-пол

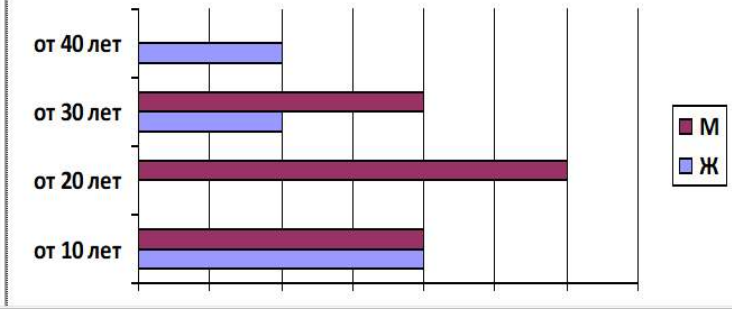

Терпения и удачи всем, кто связан с базами данных

Спасибо за внимание!

Валерий Иванович Артемьев

МГТУ имени Н.Э. Баумана, кафедра ИУ-5

Банк России
Департамент данных, проектов и процессов

Тел.: +7(495) 753-96-25
e-mail: viart@bmstu.ru